

Фамилия, имя, номер группы:

.....

Оки-доки.

(Люси Маклин из Fallout перед тем как решить эту контрольную)

Работа состоит из открытых вопросов на разные темы. На каждый из них вам необходимо дать краткие, но ёмкие ответы. Около каждого вопроса указано количество баллов, которое можно за него получить. Если у вопроса несколько подпунктов, баллы разделяются между ними равномерно.

Это демонстрационная версия, собранная из задач прошлого года. В реальной контрольной будет меньше задач, и они будут другие.

Вопрос 1. Ядерная война превратила мир в постапокалиптическую пустошь. Часть людей мутировала. Для мутантов очень важно уметь прогнозировать радиационный фон. Он представляет из себя временной ряд и измеряется с помощью счётчика Гейгера. Мутанты взяли в плен выпускника ИАДа, то есть вас, и просят помощи с прогнозированием.

1. Какие модели для прогнозирования временных рядов вы знаете? Кратко опишите две свои любимые модели.
2. Будем рассматривать конкретный момент времени как объект, а значение уровня радиации — как соответствующую целевую переменную. Чем для таких данных плоха стандартная K-Fold кросс-валидация? Как можно модернизировать её, чтобы корректно оценить качество модели, предсказывающей значение временного ряда?
3. Как при прогнозировании временного ряда можно учитывать дополнительные факторы? Например, прогноз погоды? Предложите любой разумный способ.
4. Мутанты собрали исторические данные по погоде и хотят обучить на них модель для прогнозирования радиации. При обучении они используют реальные данные, а при прогнозировании подставляют в модель прогноз погоды на завтра. К каким проблемам приведёт такой подход? Как построить модель правильно?

Вопрос 2. Ядерная война превратила мир в постапокалиптическую пустошь. Жителям пустоши не хватает красоты и эстетики. Решить их проблемы может любой выживший выпускник ИАДа, разбирающийся в генеративных моделях, то есть вы.

1. Опишите в чём заключается смысл нормализационного потока. Что обучается в рамках модели? Как применить его для генерации нового изображения?
2. Жителям пустоши хочется получить модель, которая по тексту генерировала бы картинку. Предложите пайплайн, который сделает такую генерацию.
3. Жители пустоши хотят генерировать картинки по аудио. Они говорят что-то в микрофон, а на экране появляется картинка. Предложите пайплайн, который решал бы такую задачу. На каких данных вы бы обучали такую модель?

Вопрос 3. Ядерная война превратила мир в постапокалиптическую пустошь. Братство Стали собирает довоенные технологии. Оно наткнулось на офис OpenAI и обнаружило внутри огромную языковую модель и выпускника ИАДа в криогенной заморозке рядом. Этот выпускник – вы, вас разморозили и задают вам вопросы.

1. Как выглядит пайплайн тренировки больших языковых моделей? Какие шаги он в себя включает?
2. Какие способы файн-тюнинга больших языковых моделей вы знаете? Перечислите их и кратко опишите их особенности.

Вопрос 4. Начался зомби-апокалипсис. Гриб кордицепс мутировал из-за глобального потепления и полностью подчиняет себе нервную систему заражённых людей.

Люди концентрируются в городах и огораживают их огромными стенами. В городах процветает чёрный рынок. В том числе чёрный рынок нейросетей. Вас, выпускника ИАДа, наняли как эксперта, чтобы разобраться с проблемами:

1. У торговцев есть GAN, обученный на датасете со многими видами животных, но он генерирует только картинки котиков. Какая проблема произошла при обучении? Проиллюстрируйте ее для двумерного случая.
2. Один из торговцев нашел на флэшке дискриминатор из другого GAN. Он предлагает после обычного обучения «дообучить» ваш GAN с его помощью. Как это может помочь и в чём опасность такого подхода?
3. Чёрные дельцы предлагают для нормализационного потока использовать нейронную сеть, которая принимает на вход картинки 256×256 и возвращает вектор размерности 64. Почему такую модель не получится обучить?

Вопрос 5. Начался зомби-апокалипсис. Гриб кордицепс мутировал из-за глобального потепления и полностью подчиняет себе нервную систему заражённых людей.

Чтобы лучше взаимодействовать между собой, зомби создали социальную сеть. Они поймали выпускника ИАДа, то есть вас и просят помочь сделать её лучше. Пока вы им помогаете, вас обещали не есть.

Зомби хотят реализовать внутри социальной сети механизм рекомендации нового друга. В этом им могут помочь графы. Каждая вершина – это пользователь социальной сети. Ребро между ними означает, что пользователи добавили друг-друга в друзья.

1. Опишите алгоритм Node2Vec для обучения представлений вершин графа.
2. Предположим, что мы используем в качестве функции похожести вероятность перехода из одной вершины в другую при случайном блуждании по графу. Опишите как вы будете готовить выборку для обучения Node2Vec, используя случайное блуждание.
3. Как при обучении представлений вершин графа можно учесть дополнительные факторы? Например, информацию со странички пользователя, его пол, возраст и тп.
4. Вы обучили для каждой вершины графа эмбединги. Теперь вам нужно обучить модель, которая по этим эмбедингам будет предсказывать, что два конкретных человека добавят друг-друга в друзья. Как собрать данные для обучения такой модели? Что будет таргетом? Что будет факторами? Какую модель вы обучите и как будете строить предсказание?

Вопрос 6. Начался зомби-апокалипсис. Гриб кордицепс мутировал из-за глобального потепления и полностью подчиняет себе нервную систему заражённых людей.

Лучшие умы планеты (выпускники ИАДа) расшифровали язык зомби и пытаются обучить speech2text для него. Вы руководитель исследовательской группы.

1. Опишите пайплайн, для решения такой задачи. Как вы предобработаете аудиозаписи перед обучением модели? Какую архитектуру будете использовать? Как будете разбивать данные на обучающие и тестовые?
2. Какие метрики качества для задачи распознавания текста в аудио вы знаете? Как их можно вычислить на тестовой выборке?
3. Вы обучили модель и после этого выяснили, что все данные для обучения собирались в идеальных лабораторных условиях. В полевых условиях микрофон улавливает кучу шума и распознавание речи работает на порядок хуже. Бюджета на сбор новых данных нет. Как бы вы решили эту проблему, используя старые данные?