

Прогнозирование временных рядов. Лекция 1 — Эконометрика и ML

Костромина Алина

Sber AI Lab, HSE

17.04.2025

О лекторе:

- Экономист и ML-enjoyer
- DS & Researcher at Sber AI Lab
- Занимаюсь задачами прогнозирования Time Series во всех проявлениях



Что нас ждет?

- 2 лекции и 2 семинара:
 - Первые лекция и семинар посвящены постановке задачи, классическим методам и ML
 - Вторые лекция и семинар будут про DL подходы
- Домашнее задание после второго семинара


О чем сегодня будем разговаривать?

- Как устроены временные ряды?
- Как подойти к задаче прогноза?
 - Какие модели можно использовать?
 - Как оценить качество прогноза?
 - Как правильно выделить валидационную выборку?
- Что делать, если рядов много?
- Что делать, если горизонт прогнозирования больше единицы?


Прогнозирование временных рядов

Зафиксируем терминологию

- **Временной ряд** – последовательность некоторых значений по времени.
- Если рассматриваются одновременно несколько одиночных временных рядов, то такая структура называется **многомерный временной ряд**.
- **Регулярный временной ряд** – временной ряд с равномерными временными интервалами между точками.
- Дополнительные признаки (экзогенные переменные, ковариаты) — это внешние факторы, которые не генерируются самой системой, но оказывают влияние на целевые переменные.




Пример регулярных событий



Пример **нерегулярных** событий

Прогнозирование временных рядов


Зафиксируем терминологию



Прогнозирование временных рядов

Зафиксируем терминологию


- **Задача прогнозирования** — по известной последовательности (контексту) предсказывать будущие значения на заданном горизонте прогнозирования.
- **Train_set $\neq$ History (context)**



Компоненты временного ряда


Как разделить сигнал на понятные составляющие?

- (M)STL разложение
 - Тренд
 - Сезонность (может быть несколько)
 - Остаток
- Еще отдельно выделяют **циклы** — аperiodические колебания



Сезонность vs цикл

Источник: <https://otexts.com/fpp2/stationarity.html>




Пример mstl разложения

Источник:

<https://www.statsmodels.org/dev/generated/statsmodels.tsa.seasonal.MSTL.html>

Компоненты временного ряда: виды тренда и сезонности





Компоненты временного ряда

LOESS Smoothing

Каждую точку приближаем с помощью k соседей

$$Y_i = \mu(x_i) + \epsilon_i$$

Вес каждой точки внутри окна k задаем ядром h — дистанция до самого дальнего соседа

$$w_i(x) = W\left(\frac{x_i - x}{h}\right)$$


$$W(u) = (1 - |u|^3)^3 \text{ for } |u| < 1$$

Решаем задачу локальной линейной регрессии


$$\mu(x_i) \approx \beta_0 + \beta_1(x_i - x) + \dots + \beta_p(x_i - x)^p$$

$$\sum_{i=1}^r w_i(x)(Y_i - \beta_0 - \beta_1(x_i - x) - \dots - \beta_p(x_i - x)^p)^2$$

STL



MSTL



Источники:

<https://www.nature.com/articles/s41598-023-31569-w>

<https://towardsdatascience.com/multi-seasonal-time-series-decomposition-using-mstl-in-python-136630e67530/>

<https://www.wessa.net/download/stl.pdf>



Стационарность

Постоянство свойств во времени


В узком смысле (сильная стационарность) — временной ряд $y_1 \dots, y_t$ стационарен, если для любого s совместное распределение $y_1 \dots, y_{t+s}$ не зависит от t .

В широком смысле (слабая стационарность) — временной ряд $y_1 \dots, y_t$ стационарен, если:


1. Существуют конечное матожидание $m(t)$ и дисперсия $v(t)$ в каждой точке $t \in T$.
2. $m(t) = \text{const.}$ $v(t) = \text{const.}$
3. Автоковариационная функция зависит только от разности аргументов — $\text{Cov}(y_t, y_{t+\tau}) = \gamma(\tau)$.




Mean dependent on time




Variance dependent on time




Covariance dependent on time



Mean independent on time



Variance independent on time



Covariance independent on time

Источник:

<https://medium.com/data-science/stationarity-in-time-series-a-comprehensive-guide-8beabe20d68>

Стационарность

Два наиболее популярных теста на стационарность.

Augmented Dickey-Fuller



Рассмотрим модель временного ряда (есть расширенный вариант с учетом лаговых разностей):

$$Z_t = \theta_0 + \theta_1 Z_{t-1} + \varepsilon_t$$

$H_0: \theta_1 = 1$ (ряд имеет единичный корень).

KPSS

H_0 : Ряд стационарен (по уровню или тренду).



Примеры временных рядов

Какие ряды стационарны? Какие компоненты в них можно выделить?





Figure 8.1: Which of these series are stationary? (a) Dow Jones index on 292 consecutive days; (b) Daily change in the Dow Jones index on 292 consecutive days; (c) Annual number of strikes in the US; (d) Monthly sales of new one-family houses sold in the US; (e) Annual price of a dozen eggs in the US (constant dollars); (f) Monthly total of pigs slaughtered in Victoria, Australia; (g) Annual total of lynx trapped in the McKenzie River district of north-west Canada; (h) Monthly Australian beer production; (i) Monthly Australian electricity production.

Примеры временных рядов

Какие ряды стационарны? Какие компоненты в них можно выделить?



- **Тренд:** (a), (c), (e), (f) и (i)
- **Сезонность:** (d), (h) и (i)
- **Изменение дисперсии:** (i)

(b) и (g) стационарны!

Циклы аperiодичны — их наступление непредсказуемо, поэтому их наличие не делает ряд нестационарным.





Figure 8.1: Which of these series are stationary? (a) Dow Jones index on 292 consecutive days; (b) Daily change in the Dow Jones index on 292 consecutive days; (c) Annual number of strikes in the US; (d) Monthly sales of new one-family houses sold in the US; (e) Annual price of a dozen eggs in the US (constant dollars); (f) Monthly total of pigs slaughtered in Victoria, Australia; (g) Annual total of lynx trapped in the McKenzie River district of north-west Canada; (h) Monthly Australian beer production; (i) Monthly Australian electricity production.

Источник:

<https://f0nzie.github.io/hyndman-bookdown-rsuite/stationarity-and-differencing.html>

Примеры временных рядов

Какие ряды стационарны? Какие компоненты в них можно выделить?



Нужна ли предобработка?

Универсально:

- **Логарифмирование / Вох-Сох / Yeo-Johnson** — стабилизируем дисперсию и мультипликативные эффекты (не всегда удастся подобрать хорошие параметры).
- **Сезонное дифференцирование** — удаляем сезонность.
- **Дифференцирование** — удаляем тренд и переходим к относительным изменениям.





Figure 8.4: Top panel: US net electricity generation (billion kWh). Other panels show the same data after transforming and differencing.

Нужна ли предобработка?

Больше актуально для ML и DL:

- **StandardScaler / MinMaxScaler / RobustScaler** — контролируем диапазон значений.
- **WindowNormalizing** — боремся с артефактами на уровне окон.



Перерыв на вопросы

Как получить прогнозы?

Группы методов, которые используются на практике



Naive methods

- (Seasonal) Naive
- Mean, Median



Statistical methods

- ETS
- Theta
- ARIMA



ML methods

- LinearRegression
- GradientBoosting



DL methods

- DLinear
- NBEATS
- PatchTST
- GPT4TS

Наивные модели

Наивный прогноз:

$$\hat{y}_t = y_{t-1}$$

Сезонный наивный прогноз:


$$\hat{y}_t = y_{t-m}$$

Прогноз средним значением:

$$\hat{y}_t = \bar{y} = \frac{1}{T} \sum_{t=1}^T y_t$$

Прогноз медианой:

$$\hat{y}_t = \text{median}(y_1, y_2, \dots, y_{t-1})$$



ETS

ETS (Error, Trend, Seasonality) — модель основанная на экспоненциальном сглаживании. Подходит для прогнозирования и разложения на компоненты.

Компоненты временного ряда:

$$\hat{y}_{t+h|t} = \ell_t + hb_t + s_{t+h-m(k+1)}$$

- Уровень $\ell_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(\ell_{t-1} + b_{t-1})$
- Тренд $b_t = \beta^*(\ell_t - \ell_{t-1}) + (1 - \beta^*)b_{t-1}$
- Сезонность $s_t = \gamma(y_t - \ell_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$

Спецификация модели зависит от трех параметров:

Пример: ETS(AAA)

- Вид ошибок (**Error**): аддитивные (A), мультипликативные (M)
- Тренд (**Trend**): нет (N), аддитивный (A), мультипликативный (M)
+ варианты с затуханием (Ad и Md)
- Сезонность (**Seasonality**): нет (N), аддитивная (A), мультипликативная (M)

Theta

Основная идея:

- Выделить из ряда несколько “тета”-рядов
- Спрогнозировать их
- Усреднить


“Тета”-ряды, соответствующие разным значениям θ содержат разную информацию о локальной кривизне ряда

Алгоритм из оригинальной статьи:

1. Извлечь сезонную компоненту из ряда
2. Посчитать “тета”-ряды для $\theta=0$ (линейный тренд) и $\theta=2$
3. Экстраполировать линейный тренд, а второй ряд продолжить экспоненциальным сглаживанием
4. Усреднить прогнозы для “тета”-рядов
5. Вернуть сезонную компоненту

$$Y''_{t,\theta} = \theta X''_t$$

$$Y_{t,\theta} = a_\theta + b_\theta(t - 1) + \theta X_t$$



Источник:

Assimakopoulos, V., & Nikolopoulos, K. (2000). The theta model: a decomposition approach to forecasting. *International journal of forecasting*, 16(4), 521-530.

ARIMA

AR(p) (Autoregression) - модель авторегрессии порядка p .

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$$

MA(q) (Moving average) - модель скользящего среднего порядка q :

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

Если объединим две модели, то получим **ARMA(p, q)** модель:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

Теоретическая мотивация: любой стационарный в широком смысле процесс можно аппроксимировать с заданной точностью, выбрав необходимые p и q .

ARIMA(p, d, q) является расширением модели ARMA на нестационарные ряды:

$$\Delta^d y_i = c + \sum_{j=1}^p \phi_j \Delta^d y_{i-j} + \varepsilon_i + \sum_{j=1}^q \theta_j \varepsilon_{i-j}$$

где d - порядок дифференцирования для приведения ряда к стационарному

SARIMAX

В модель можно добавить внешние факторы (eXogenous), тогда мы получим **ARIMAX(p, d, q)**:

$$\Delta^d y_t = c + \sum_{i=1}^p \phi_i \Delta^d y_{t-i} + \sum_{k=1}^K \beta_k X_{k,t} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

Таким образом, если собрать все воедино, то получим **SARIMAX(p, d, q)(P, D, Q, s)**:

- Работает с нестационарными рядами
- Учитывает дополнительные факторы
- Моделирует сезонные паттерны

Как подбирать гиперпараметры:

<https://people.duke.edu/~rnau/arimrule.htm>

SARIMA(p, d, q)(P, D, Q, s) - расширение модели ARIMA для учета сезонности:

- s - период сезонности
- P - порядок сезонной AR части
- D - порядок сезонного дифференцирования ряда
- Q - порядок сезонной MA части

Почему нужно что-то еще?

Классические модели:

- Зачастую требуют ручной предобработки
- Ограниченно поддерживают экзогенные признаки
- Не помогут, если рядов много

Перерыв на вопросы

Как не запутаться в `pd.Series.shift(...)`?

Временной ряд можно представить в виде таблицы признаков и использовать знакомые ML и DL методы вместо специализированных моделей

«Длинная» таблица с
временным рядом

STEP [
 L
 H]


time	value	Additional features
0	4	...
1	4	...
2	5	...
3	6	...
4	3	...
5	2	...
6	8	...

H = 2
L = 3
STEP = 1

Составляем индексы

id	long ids features	long ids targets
0	[0, 1, 2]	[3, 4]
1	[1, 2, 3]	[4, 5]
2	[2, 3, 4]	[5, 6]

Train Set History (context) Forecast




«Широкая» таблица со
сгенерированными признаками

Base ts	Current Value	Max Value	target1	target2
2	5	5	6	3
3	6	6	3	2
4	3	6	2	8

Какие признаки использовать?

- **Календарные признаки**
 - День недели, месяц, год (категориальные переменные)
 - Признаки на основе разложения Фурье
- **Лаговые признаки и признаки на основе разностей**
 - Значение вчера или год назад
 - Разница между текущим значением и значением вчера или год назад
- **Групповые статистики**
 - Средние, медианы, квантильные значения по группам (например, по дням недели)
 - Скользящие средние и стандартные отклонения (например, за 7 и 30 дней)
- **Признаки на основе статистических моделей**
 - ARIMA- или ETS-компоненты



Как получить прогнозы?

Группы методов, которые используются на практике



Naive methods

- (Seasonal) Naive
- Mean, Median



Statistical methods

- ETS
- Theta
- ARIMA



ML methods

- LinearRegression
- GradientBoosting



DL methods

- DLinear
- NBEATS
- PatchTST
- GPT4TS

Начинаем всегда с них!

Как оценить качество прогноза?

Существует множество вариантов метрик, но нет ни одной универсальной

- Лучше использовать сразу несколько.

1 Scale-Dependent

MSE (Mean Squared Error)

$$MSE = \frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2$$

MAE (Mean Absolute Error)

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

MdAE (Median Absolute Error)

$$MdAE = \text{median}(|y_t - \hat{y}_t|)$$

2 Scale-Independent

MAPE (Mean Absolute Percentage Error)

$$MAPE = 100 \times \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

SMAPE (Symmetric Mean Absolute Percentage Error)

$$SMAPE = 100 \times \frac{1}{n} \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{\frac{|y_t| + |\hat{y}_t|}{2}}$$

msMAPE (Modified SMAPE)

$$msMAPE = 100 \times \frac{1}{n} \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{\frac{\max(|y_t| + |\hat{y}_t| + \epsilon, 0.5 + \epsilon)}{2}}$$

3 Relative

RelRMSE (Relative RMSE)

$$RelRMSE = \sqrt{\frac{MSE}{MSE_{baseline}}}$$

RelMAE (Relative MAE)

$$RelMAE = \frac{MAE}{MAE_{baseline}}$$

MASE (Mean Absolute Scaled Error)


$$MASE = \frac{MAE}{\frac{n}{m-s} \sum_{k=s+1}^m |y_k - y_{k-s}|}$$

Как оценить качество прогноза?


1 Blocked KFold




2 Rolling window



3 Expanding window




4 Holdout



Перерыв на вопросы


А если много рядов?

Local



Много моделей, по одной для каждого временного ряда.


Multivariate



Одна модель для всех одномерных временных рядов.

Признаки наблюдений, относящихся к одной временной точке, **объединяются**

Global




Одна модель для всех одномерных временных рядов.

Признаки отдельных наблюдений **не пересекаются** между рядами.

А если много точек в горизонте прогнозирования?

Ряды на несколько точек вперед можно прогнозировать по-разному



Пусть $L = 7$, $H = 3$, $N = 11$ (где N – длина всего ряда).



Тогда по значениям в моменты времени от 0 до 10 хотим предсказать значения в моменты времени от 11 до 13.

Рассмотрим, как использовать разные стратегии в этой постановке.

MIMO (Multi-In-Multi-Out)


Одна модель для всех точек горизонта прогнозирования.

- Учим модель предсказывать сразу на H точек вперед.



Recursive / Rec-MIMO


- Учим модель предсказывать на h точек вперед.
- Итеративно строим прогнозы на основе уже полученных прогнозов.



Direct / Direct-MIMO

Индивидуальная модель для каждой точки горизонта прогнозирования.

- Учим i -ую модель предсказывать на h точек вперед через $(i - 1) \times h$ точек.
- Одновременно строим прогнозы.



FlatWideMIMO

Одна модель для всех точек горизонта прогнозирования.

- Развернутый по горизонтам предсказания MIMO.
- Похоже на прямую стратегию, но при этом обучается только одна модель и есть доп. признак горизонта, которым мы управляем и который означает, на какой момент делать предсказание.

HF

1	0	1	2	3	4	5	6	7
2	0	1	2	3	4	5	6	8
3	0	1	2	3	4	5	6	9
4	0	1	2	3	4	5	6	10
1	1	2	3	4	5	6	7	8
2	1	2	3	4	5	6	7	9
3	1	2	3	4	5	6	7	10
1	2	3	4	5	6	7	8	9
2	2	3	4	5	6	7	8	10
1	3	4	5	6	7	8	9	10

HF

1	4	5	6	7	8	9	10	11
2	4	5	6	7	8	9	10	12
3	4	5	6	7	8	9	10	13

А если много точек в горизонте прогнозирования?




std / strategy

Recursive




RecMIMO 10

MIMO




0.1



0.7



1




Библиотека о стратегиях прогнозирования



<https://github.com/sb-ai-lab/tsururu>



Tsururu



Спасибо за внимание!

Костромина Алина
Sber AI Lab, HSE

