

Прогнозирование временных рядов.

Лекция 2 — DL

Костромина Алина

Sber AI Lab, HSE

24.04.2025

В предыдущих сериях

- Определили задачу прогнозирования временного ряда
- Поговорили о том:
 - Какие модели можно использовать?
 - Как оценить качество прогноза?
 - Как правильно выделить валидационную выборку?
- Познакомились с разными стратегиями прогнозирования нескольких временных рядов на несколько точек вперед

О чем сегодня будем разговаривать?

- Какие современные методы прогнозирования можно использовать в своих задачах?
- Что такое zero-shot прогнозирование и почему оно набирает популярность?
- Как избежать наиболее распространенные ошибки при анализе временных рядов? С какими проблемами можно столкнуться?

Supervised подход к прогнозированию рядов


Stat & ML

Stat

- (Seasonal) Naive
- ARIMA
- ETS
- Theta

ML

- Sklearn-like models
- CatBoost / PyBoost



DL

Linear

- [DLinear](#)
- [CycleNet](#)

CNN

- [TimesNet](#)

Transformers

- [GPT4TS](#)
- [PatchTST](#)
- [Crossformer](#)
- [iTransformer](#)

Supervised: Train the model to predict labels for new data, based on patterns identified in the train set.

DLinear (2023, AAAI)

Идея: выделяем тренд и используем простые линейные модели на компоненты (тренд и остаток)

$$\hat{X}_i = W X_i \quad W \in \mathbb{R}^{T \times L}$$


С помощью AvgPool выделяем тренд.
Все остальное — остаток (seasonal)

$$\mathcal{X}_t = \text{AvgPool}(\text{Padding}(\mathcal{X}))$$

$$\mathcal{X}_s = \mathcal{X} - \mathcal{X}_t,$$

Используем
отдельные модели
(nn.Linear)

Суммируем и
получаем прогноз



Так выглядит базовая линейная модель для компонентов

Code: <https://github.com/vivva/DLinear>

Paper: <https://arxiv.org/abs/2205.13504>


CycleNet (2024, NeurIPS)

Идея: выделяем циклы и используем линейную модель на остатки

С помощью обучаемых шаблонов выделяем сезонность
Все остальное — остаток

Используем линейную модель / MLP на остаток

Суммируем и получаем прогноз



L — длина контекста (история)
Ищем в данных обучаемые повторяющиеся сезонные паттерны, удаляем и остаток приближаем основной моделью => затем собираем обратно в прогноз

Code: <https://github.com/ACAT-SCUT/CycleNet>

Paper: <https://arxiv.org/abs/2409.18479>

TimesNet (2023, ICLR)

Идея: использовать 2D представления временных рядов в разрезе разных периодичностей. Учет intra-period & inter-period взаимосвязей между рядами

Определяем top-k частот с наибольшей амплитудой в FFT блоке


Разбиваем ряд в разрезе разных периодов, формируем 2D представления

2D-CNN (TimesBlock)

Адаптивная агрегация + линейная голова

Code: <https://github.com/thuml/Time-Series-Library>

Paper: <https://arxiv.org/abs/2210.02186>



PatchTST (2023, ICLR)


Идея: одно наблюдение в конкретный момент времени несет мало информации (как один пиксель в картинке) - лучше рассматривать “патчи”

Нормализуем и патчим входную последовательность

Получаем эмбединги, которые отправляем в трансформерный encoder

Используем Flatten + линейную голову для получения предсказаний

Code: <https://github.com/yuqinie98/PatchTST>
Paper: <https://arxiv.org/abs/2211.14730>




GPT4TS (2023, NeurIPS)

Идея: используем предобученные на других доменах трансформеры (GPT2, BERT)

Нормализуем и патчим входную последовательность

Получаем эмбединги, которые отправляем в предобученный трансформер с замороженными основными слоями

Используем линейную голову для получения предсказаний



Code: <https://github.com/DAMO-DI-ML/NeurIPS2023-One-Fits-All>

Paper: <https://arxiv.org/abs/2302.11939>

Архитектуры: Zero-shot

LLM

Non-adapted LLM

- [LSTPrompt](#)
- [PromptCast](#)
- [LLMTime](#)

Adapted LLM

- [Time-LLM](#)
- [FPT](#)
- [Chronos](#)
- [UniTS](#)
- [DAM](#)


Specialized

Using synthetic data

- [ForecastPFN](#)

Using real data


- [GPHT](#)
- [MOIRAI](#)
- [Moment](#)



Zero-shot: Train the model to predict labels for new data **without training on the target dataset**, based on patterns identified in the unrelated data.

Обучение Zero-shot models for time series


Zero-shot модели для временных рядов – это в основном трансформеры. Также они требуют большой разнообразный датасет для предобучения.



Данные для обучения zero-shot модели

Модель предсказывает те особенности (длина периода, тренд), которые заложены в данных

Датасеты для обучения



LLMTime (2023, NeurIPS)

Идея и Архитектура: кодируем последовательность как текст и используем любую из доступных LLM.

Как кодировать временной ряд?

Rescaling

$$x_t \rightarrow \frac{x_t - b}{a} \quad \left\{ \begin{array}{l} b = \min_t x_t - \beta \cdot (\max_t x_t - \min_t x_t) \\ a = a\text{-percentile}(x_1 - b, x_2 - b, \dots, x_T - b) \end{array} \right.$$


Type-changing 0.123, 1.23, 12.3, 123.0 → "12,123,1230,12300"

Tokenization

"151,167,...,267"

"151,167,...,267"

alpha=0.95, beta=0.3






Упрощенно, задача прогноза — это та же задача продолжения последовательности

Code: <https://github.com/ngruver/llmtime>

Paper: <https://arxiv.org/abs/2310.07820>

CHRONOS (2024, TMLR)

Идея и Архитектура: кодируем последовательность как текст и используем любую из доступных LLM (T5). Только теперь с дообучением на синтетических и реальных данных с применением TSMixup аугментации (~84 млрд).



Code: <https://github.com/amazon-science/chronos-forecasting>


Paper: <https://arxiv.org/abs/2403.07815>

TimesFM (2024, ICML)

Идея: обучаем трансформерный decoder на большом количестве синтетических и реальных рядов (~370 млрд).

Задачи: forecasting (+ quantile)

Постановка: univariate
(+ exogenous features)



Code: <https://github.com/google-research/timesfm>


Paper: <https://arxiv.org/abs/2310.10688v2>

Moirai (2024, PMLR)

Идея: маскированная encoder-only модель, предобученная на рядах с различной грануляцией (~27 млрд наблюдений).

Задача: probabilistic forecasting

Архитектура: RoPE эмбеддинг, flatten для multivariate данных, благодаря чему может обрабатывать данные с произвольной размерностью.



9 доменов. Разная гранулярность — от года до секунды




Code: <https://github.com/SalesforceAIResearch/uni2ts>

Paper: <https://arxiv.org/abs/2402.02592>

Типичные ошибки

- 1) Избегать препроцессинга
- 2) Допускать лики в процессе валидации модели
- 3) Не подбирать метрики под конкретную задачу
- 4) Игнорировать бейзлайны




Пример, когда модели ML и DL плохо справляются с прогнозом нестационарного ряда


Типичные ошибки

5) Неправильно строить и анализировать графики прогнозов

- Понятно ли, какой горизонт прогнозирования и на каких данных обучается / дообучается модель?
- Понятно ли, какая модель лучше других?
- Понятно ли, насколько предсказания близки к реальным значениям?



(a) Series with unit root based non-stationarity and forecasts from different models



(b) Forecasts from the different models on a selected subset of the test set (timestamps 807 - 856)

С чем еще можно столкнуться?

- Коррекция остатков
- Иерархические прогнозы
- Intermittent / Sparse временные ряды (где много нулей)
- Нерегулярные ряды
- Интервальные прогнозы

Куда обращаться?

- <https://otexts.com/fpp3/some-simple-statistics.html> — **Forecasting: Principles and Practice (3rd ed)** (Rob J Hyndman and George Athanasopoulos): несложный учебник, к которому можно обращаться как к входной точке, если возникла проблема
- https://www.youtube.com/watch?v=S_Z8RnTE5dl&t=5463s — 2.5-часовая **лекция Christoph Bergmeir** про прогнозирование временных рядов
- <https://nixtlaverse.nixtla.io/statsforecast/index.html> — **statsforecast (Nixtla)**: удобное построение бейзлайнов
- <https://github.com/sb-ai-lab/tsururu> — **Tsururu**: быстрая проверка гипотез относительно препроцессинга, стратегий и модели
- <https://github.com/etna-team/etna> — **ETNA**: довольно много всего для конструирования признаков
- <https://unit8co.github.io/darts/> — **DARTS**: тяжеловесная, но мощная библиотека для нестандартных задач

Спасибо за внимание!

Костромина Алина
Sber AI Lab, HSE

