



¹Высшая Школа Экономики,

²Институт теоретической
физики им. Л.Д. Ландау,

³Институт Земного магнетизма,
ионосферы и распространения
радиоволн им. Н.В. Пушкова
РАН

12 июня 2025 г.

Нейронные сети в физике и физика в нейронных сетях

Илья Никитин^{1,2,3}



План лекции

1. Примеры применения классических нейросетей в задачах физики и астрономии
2. Что такое дифференциальное уравнение? Как управляются физические системы?
3. Дилемма о данных и знаниях. Другие подходы к задачам физики. Идея Physics-Informed Neural Network (PINN).
4. PINN: архитектура, лосс и автоматическое дифференцирование.
5. Backward PINN. Преимущества и проблемы PINN.



Нейронные сети в физике 1




Рис.: Определение заряда исходного кварка из данных с матрицы коллайдера



Нейронные сети в физике 2






Рис.: Аппроксимация распределения состояний в модели Изинга при разных температурных режимах

D'Angelo F. et al., Learning the Ising model with generative neural networks, Phys. Rev. Research, 2020



Нейросети в астрономии 1



S. Voskresenskaia et al. ComPACT: combined Atacama Cosmology Telescope + Planck galaxy cluster catalogue, Monthly Notices of the Royal Astronomical Society, 2024



Нейросети в астрономии 2








Рис.: Модель, классифицирующая спиральные галактики

Michael J. Smith et al. Astronomia ex machina: a history, primer and outlook on neural networks in astronomy, Royal Society Open Science Volume 10, Issue 5, 2023




Нейросети в астрономии 3: Солнечные магнитные торнадо








Нейросети в астрономии 3: Солнечные магнитные торнадо





Нейросети в астрономии 3: Солнечные магнитные торнадо.



- Создана база данных торнадо
- Модель может быть использована для сбора статистики
- Проверка гипотез о физике явления



План лекции

1. Примеры применения классических нейросетей в задачах физики и астрономии
2. Что такое дифференциальное уравнение? Как управляются физические системы?
3. Дилемма о данных и знаниях. Другие подходы к задачам физики. Идея Physics-Informed Neural Network (PINN).
4. PINN: архитектура, лосс и автоматическое дифференцирование.
5. Backward PINN. Преимущества и проблемы PINN.



Что такое дифференциальное уравнение?

1. *Дифференциальное уравнение*
описывает закон изменения
чего-либо (например, температуры,
скорости, концентрации).



Что такое дифференциальное уравнение?

1. *Дифференциальное уравнение*
описывает закон изменения
чего-либо (например, температуры,
скорости, концентрации).
2. Связывает функцию, её
производные и внешние слагаемые.



Что такое дифференциальное уравнение?

1. *Дифференциальное уравнение* описывает закон изменения чего-либо (например, температуры, скорости, концентрации).
2. Связывает функцию, её производные и внешние слагаемые.
3. Чтобы полноценно решить дифференциальное уравнение, нужны начальные условия.



Что такое дифференциальное уравнение?

1. Дифференциальное уравнение описывает закон изменения чего-либо (например, температуры, скорости, концентрации).
2. Связывает функцию, её производные и внешние слагаемые.
3. Чтобы полноценно решить дифференциальное уравнение, нужны начальные условия.

Пример:

$$\frac{dy}{dt} = -ky \quad (1)$$

Закон описывает радиоактивный распад, охлаждение тела, рост(вымирание) популяции и т.д.




Рис.: Экспоненциальный радиоактивный распад



Что такое дифференциальное уравнение?

ODE – обыкновенные
дифференциальные уравнения, они
зависят от одной переменной



Что такое дифференциальное уравнение?

ODE – обыкновенные
дифференциальные уравнения, они
зависят от одной переменной

Пример:

$$\frac{dv}{dt} = -g \quad \Rightarrow \quad v(t) = v_0 - gt \quad (2)$$

Этот закон описывает скорость тела,
падающего в гравитационном поле.



Что такое дифференциальное уравнение?

ODE – обыкновенные дифференциальные уравнения, они зависят от одной переменной
Пример:

$$\frac{dv}{dt} = -g \quad \Rightarrow \quad v(t) = v_0 - gt \quad (2)$$

Этот закон описывает скорость тела, падающего в гравитационном поле.

Уравнения в частных производных (PDE)
— зависят от нескольких переменных, например, времени и координаты. Чтобы решить PDE, нужно, помимо начальных условий, знать граничные условия.



Что такое дифференциальное уравнение?

ODE – обыкновенные дифференциальные уравнения, они зависят от одной переменной

Пример:

$$\frac{dv}{dt} = -g \quad \Rightarrow \quad v(t) = v_0 - gt \quad (2)$$

Этот закон описывает скорость тела, падающего в гравитационном поле.

Уравнения в частных производных (PDE) — зависят от нескольких переменных, например, времени и координаты. Чтобы решить PDE, нужно, помимо начальных условий, знать граничные условия.

Пример:

$$\frac{\partial u}{\partial t} = \alpha \frac{\partial^2 u}{\partial x^2} \quad (3)$$

Закон описывает эволюцию температуры стержня.



Решение дифференциальных уравнений

Решать дифференциальные уравнения непросто. Искать аналитические решения получается только у линейных уравнений, для сложных систем приходится прибегать к **численным решениям**.



Решение дифференциальных уравнений

Решать дифференциальные уравнения непросто. Искать аналитические решения получается только у линейных уравнений, для сложных систем приходится прибегать к **численным решениям**.




Рис.: Пример алгоритма численного решения дифференциального уравнения



Решение дифференциальных уравнений

Решать дифференциальные уравнения непросто. Искать аналитические решения получается только у линейных уравнений, для сложных систем приходится прибегать к **численным решениям**.




Рис.: Пример алгоритма численного решения дифференциального уравнения

Методы численного решения не всегда хорошо сходятся и, кроме того, они не умеют решать обратные задачи.



Дифференциальные уравнения: суммарайз

1. Дифференциальные уравнения управляют физическими (на самом деле не только физическими) системами



Дифференциальные уравнения: суммарайз

1. Дифференциальные уравнения управляют физическими (на самом деле не только физическими) системами
2. Чтобы решить такое уравнение, **нужно знать начальные и граничные условия**. (Например, знать как была устроена скорость жидкости в начальный момент времени, а также скорость на границе наблюдаемого сосуда, чтобы найти скорость в любой момент времени)



Дифференциальные уравнения: суммарайз

1. Дифференциальные уравнения управляют физическими (на самом деле не только физическими) системами
2. Чтобы решить такое уравнение, **нужно знать начальные и граничные условия**. (Например, знать как была устроена скорость жидкости в начальный момент времени, а также скорость на границе наблюдаемого сосуда, чтобы найти скорость в любой момент времени)
3. Решать такие уравнения непросто. Численные методы имеют ограниченный функционал и не всегда хорошо сходятся.



1. Примеры применения классических нейросетей в задачах физики и астрономии
2. Что такое дифференциальное уравнение? Как управляются физические системы?
3. Дилемма о данных и знаниях. Другие подходы к задачам физики. Идея Physics-Informed Neural Network (PINN).
4. PINN: архитектура, лосс и автоматическое дифференцирование.
5. Backward PINN. Преимущества и проблемы PINN.



Дилемма о данных и знаниях




Рис.: Иллюстрация, демонстрирующая разные классы систем. Слева имеем системы, которые управляются уравнениями, для таких систем иногда сложно собрать большое количество данных. Справа системы, для которых можно собрать большие данные, но сложно записать и решить уравнения. По центру что-то промежуточное.



Universal Differential Equations

Universal Differential Equations (UDE) – метод аппроксимации неизвестных слагаемых в физических уравнениях.



Universal Differential Equations

Universal Differential Equations (UDE) – метод аппроксимации неизвестных слагаемых в физических уравнениях.

1. Есть изолированная система, для которой знаем дифференциальное уравнение.



Universal Differential Equations

Universal Differential Equations (UDE) – метод аппроксимации неизвестных слагаемых в физических уравнениях.

1. Есть изолированная система, для которой знаем дифференциальное уравнение.
2. Система перестает быть изолированной. Уравнение больше не работает.



Universal Differential Equations

Universal Differential Equations (UDE) – метод аппроксимации неизвестных слагаемых в физических уравнениях.

1. Есть изолированная система, для которой знаем дифференциальное уравнение.
2. Система перестает быть изолированной. Уравнение больше не работает.
3. Записываем неполное уравнение и прибавляем неизвестный член.

$$u' = f(u, t, p) + U_\theta(u) \quad (4)$$



Universal Differential Equations

Universal Differential Equations (UDE) – метод аппроксимации неизвестных слагаемых в физических уравнениях.

1. Есть изолированная система, для которой знаем дифференциальное уравнение.
2. Система перестает быть изолированной. Уравнение больше не работает.
3. Записываем неполное уравнение и прибавляем неизвестный член.

$$u' = f(u, t, p) + U_{\theta}(u) \quad (4)$$

4. Аппроксимируем неизвестную функцию с помощью нейронной сети, обученной на экспериментальных данных.



Physics Informed Neural Networks (PINN)

Предположим, что у нас есть знание о граничных и начальных условиях системы, а также знание об уравнениях, которые управляют системой.



Physics Informed Neural Networks (PINN)

Предположим, что у нас есть знание о граничных и начальных условиях системы, а также знание об уравнениях, которые управляют системой.

1. Возьмем нейронную сеть, которая будет на выходе выдавать искомую функцию u , а на вход принимать ее переменные (например, время и координаты).



Physics Informed Neural Networks (PINN)

Предположим, что у нас есть знание о граничных и начальных условиях системы, а также знание об уравнениях, которые управляют системой.

1. Возьмем нейронную сеть, которая будет на выходе выдавать искомую функцию u , а на вход принимать ее переменные (например, время и координаты).
2. Задаем лосс, минимум которого достигается при удовлетворении уравнениям, а также начальным и граничным условиям.



Physics Informed Neural Networks (PINN)

Предположим, что у нас есть знание о граничных и начальных условиях системы, а также знание об уравнениях, которые управляют системой.

1. Возьмем нейронную сеть, которая будет на выходе выдавать искомую функцию u , а на вход принимать ее переменные (например, время и координаты).
2. Задаем лосс, минимум которого достигается при удовлетворении уравнениям, а также начальным и граничным условиям.
3. Оптимизируем сеть и получаем $\text{NN}(x, \dots, t) \rightarrow u(x, \dots, t)$ – численно приближили решение дифференциального уравнения (unsupervised подходом!)

Это и называется *Physics-Informed Neural Network*.



PINN: Общая идея




Рис.: Иллюстрация подхода PINN



1. Примеры применения классических нейросетей в задачах физики и астрономии
2. Что такое дифференциальное уравнение? Как управляются физические системы?
3. Дилемма о данных и знаниях. Другие подходы к задачам физики. Идея Physics-Informed Neural Network (PINN).
4. PINN: архитектура, лосс и автоматическое дифференцирование.
5. Backward PINN. Преимущества и проблемы PINN.



PINN: Архитектура

Сама нейросеть может быть какой угодно, популярные варианты:



PINN: Архитектура

Сама нейросеть может быть какой угодно, популярные варианты:

- В большинстве задач используется архитектура MLP за счет простоты, иногда добавляются модификации (ResNet, Fourier Features)



PINN: Архитектура

Сама нейросеть может быть какой угодно, популярные варианты:

- В большинстве задач используется архитектура MLP за счет простоты, иногда добавляются модификации (ResNet, Fourier Features)
- Для двумерных данных можно использовать сверточные сети (CNN).



PINN: Архитектура

Сама нейросеть может быть какой угодно, популярные варианты:

- В большинстве задач используется архитектура MLP за счет простоты, иногда добавляются модификации (ResNet, Fourier Features)
- Для двумерных данных можно использовать сверточные сети (CNN).
- Для графовых задач можно использовать графовые нейронные сети (GNN)



PINN: Архитектура

Сама нейросеть может быть какой угодно, популярные варианты:

- В большинстве задач используется архитектура MLP за счет простоты, иногда добавляются модификации (ResNet, Fourier Features)
- Для двумерных данных можно использовать сверточные сети (CNN).
- Для графовых задач можно использовать графовые нейронные сети (GNN)
- Есть примеры использования RNN-like сетей.



PINN: Лосс

Пусть уравнение задается как

$$f(u(x, t), \partial_t u(x, t), \partial_x^2 u(x, t), \dots) = 0 \quad (5)$$



Пусть уравнение задается как

$$f(u(x, t), \partial_t u(x, t), \partial_x^2 u(x, t), \dots) = 0 \quad (5)$$

Начальные условия запишем как

$$u(x, 0) = u_0(x) \quad (6)$$



PINN: Лосс

Пусть уравнение задается как

$$f(u(x, t), \partial_t u(x, t), \partial_x^2 u(x, t), \dots) = 0 \quad (5)$$

Начальные условия запишем как

$$u(x, 0) = u_0(x) \quad (6)$$

Граничные условия

$$u(0, t) = 0, \quad \left. \frac{\partial u(x, t)}{\partial x} \right|_{x=L} = 0, \quad \dots \quad (7)$$



PINN: Лосс

Пусть уравнение задается как

$$f(u(x, t), \partial_t u(x, t), \partial_x^2 u(x, t), \dots) = 0 \quad (5)$$

Начальные условия запишем как

$$u(x, 0) = u_0(x) \quad (6)$$

Граничные условия

$$u(0, t) = 0, \quad \left. \frac{\partial u(x, t)}{\partial x} \right|_{x=L} = 0, \quad \dots \quad (7)$$

Компоненты лосса запишем как

$$\mathcal{L}_{\text{PDE}} = \text{MSE} \left[0, f(\text{NN}(x, t), \partial_t \text{NN}(x, t), \partial_x^2 \text{NN}(x, t), \dots) \right], \quad (8)$$

$$\mathcal{L}_{\text{IC}} = \text{MSE} [u_0(x), \text{NN}(x, 0)] \quad (9)$$

$$\mathcal{L}_{\text{BC}} = \text{MSE} [0, \text{NN}(0, t)] + \text{MSE} \left[0, \left. \frac{\partial}{\partial x} \text{NN}(x, t) \right|_{x=L} \right] + \dots \quad (10)$$



PINN: Лосс

Пусть уравнение задается как

$$f(u(x, t), \partial_t u(x, t), \partial_x^2 u(x, t), \dots) = 0 \quad (5)$$

Компоненты лосса запишем как

Начальные условия запишем как

$$u(x, 0) = u_0(x) \quad (6)$$

$$\mathcal{L}_{\text{PDE}} = \text{MSE} \left[0, f(\text{NN}(x, t), \partial_t \text{NN}(x, t), \partial_x^2 \text{NN}(x, t), \dots) \right], \quad (8)$$

$$\mathcal{L}_{\text{IC}} = \text{MSE} [u_0(x), \text{NN}(x, 0)] \quad (9)$$

Граничные условия

$$u(0, t) = 0, \quad \left. \frac{\partial u(x, t)}{\partial x} \right|_{x=L} = 0, \quad \dots \quad (7)$$

$$\mathcal{L}_{\text{BC}} = \text{MSE} [0, \text{NN}(0, t)] + \text{MSE} \left[0, \left. \frac{\partial}{\partial x} \text{NN}(x, t) \right|_{x=L} \right] + \dots \quad (10)$$

Лосс запишем как сумму трех слагаемых

$$\mathcal{L}_{\text{Total}} = \underbrace{\mathcal{L}_{\text{PDE}}}_{\text{дифф. уравнения}} + \underbrace{\mathcal{L}_{\text{IC}}}_{\text{нач. условия}} + \underbrace{\mathcal{L}_{\text{BC}}}_{\text{гран. условия}} \quad (11)$$



PINN: autograd

При обучении PINN сеть должна вычислять производные выхода по входам (производные 1-го, 2-го порядка и т.д.). В фреймворке torch есть autograd, который умеет вычислять такие производные.



PINN: autograd

При обучении PINN сеть должна вычислять производные выхода по входам (производные 1-го, 2-го порядка и т.д.). В фреймворке torch есть autograd, который умеет вычислять такие производные.


1. Строим граф вычислений (композиция элементарных операций: $+$, $*$, $\tanh$ и т.д.)
2. Forward: вычисляются значения на узлах
3. Backward: вычисляем частные производные с помощью backpropagation.



PINN: autograd

При обучении PINN сеть должна вычислять производные выхода по входам (производные 1-го, 2-го порядка и т.д.). В фреймворке torch есть autograd, который умеет вычислять такие производные.

1. Строим граф вычислений (композиция элементарных операций: $+$, $*$, $\tanh$ и т.д.)
2. Forward: вычисляются значения на узлах
3. Backward: вычисляем частные производные с помощью backpropagation.



sidite.com



Рис.: Граф вычислений



PINN: autograd

При обучении PINN сеть должна вычислять производные выхода по входам (производные 1-го, 2-го порядка и т.д.). В фреймворке torch есть autograd, который умеет вычислять такие производные.

1. Строим граф вычислений (композиция элементарных операций: $+$, $*$, $\tanh$ и т.д.)
2. Forward: вычисляются значения на узлах
3. Backward: вычисляем частные производные с помощью backpropagation.



sidibe.com

Рис.: Граф вычислений

Profit: научились считать производные $\partial_t u, \partial_x u, \partial_{xx} u, \dots$ для вычисления loss функции.



PINN: дубль два




Рис.: Иллюстрация подхода PINN



Forward PINN: пример





Рис.: Пример решения нелинейного одномерного уравнения Шредингера, сгенерированы точки на пространственных границах.




Forward PINN: пример



$$f := \frac{\partial V}{\partial t} + \frac{1}{2}\sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} + rS \frac{\partial V}{\partial S} - rV = 0$$

Analytical Soln



PINN prediction




Рис.: Пример решения уравнения Блэка-Шоулза, задача вычисления справедливой цены опциона.



План лекции

1. Примеры применения классических нейросетей в задачах физики и астрономии
2. Что такое дифференциальное уравнение? Как управляются физические системы?
3. Дилемма о данных и знаниях. Другие подходы к задачам физики. Идея Physics-Informed Neural Network (PINN).
4. PINN: архитектура, лосс и автоматическое дифференцирование.
5. Backward PINN. Преимущества и проблемы PINN.



Backward PINN

До этого мы решали задачу, которую можно решить численными методами – знаем уравнение, начальные и граничные условия и хотим получить решение. Давайте попробуем **решить обратную задачу**.



Backward PINN

До этого мы решали задачу, которую можно решить численными методами – знаем уравнение, начальные и граничные условия и хотим получить решение. Давайте попробуем **решить обратную задачу**.

- Пусть есть набор разреженных данных. Измерения функции u в каком-то наборе точек $\{x_i, t_i\}_{i=0,1,\dots,N}$



Backward PINN

До этого мы решали задачу, которую можно решить численными методами – знаем уравнение, начальные и граничные условия и хотим получить решение. Давайте попробуем **решить обратную задачу**.

- Пусть есть набор разреженных данных. Измерения функции u в каком-то наборе точек $\{x_i, t_i\}_{i=0,1,\dots,N}$
- Знаем уравнение, но не полностью. Например, нам неизвестна функция (внешняя сила, давление), или отдельные скалярные параметры (вязкость жидкости, трение о дно, безрисковая процентная ставка, волатильность актива).



Backward PINN

До этого мы решали задачу, которую можно решить численными методами – знаем уравнение, начальные и граничные условия и хотим получить решение. Давайте попробуем **решить обратную задачу**.

- Пусть есть набор разреженных данных. Измерения функции u в каком-то наборе точек $\{x_i, t_i\}_{i=0,1,\dots,N}$
- Знаем уравнение, но не полностью. Например, нам неизвестна функция (внешняя сила, давление), или отдельные скалярные параметры (вязкость жидкости, трение о дно, безрисковая процентная ставка, волатильность актива).
- Хотим **восстановить неизвестные параметры и функции** так, чтобы получившееся уравнение удовлетворяло нашему набору измерений.



Backward PINN

До этого мы решали задачу, которую можно решить численными методами – знаем уравнение, начальные и граничные условия и хотим получить решение. Давайте попробуем **решить обратную задачу**.

- Пусть есть набор разреженных данных. Измерения функции u в каком-то наборе точек $\{x_i, t_i\}_{i=0,1,\dots,N}$
- Знаем уравнение, но не полностью. Например, нам неизвестна функция (внешняя сила, давление), или отдельные скалярные параметры (вязкость жидкости, трение о дно, безрисковая процентная ставка, волатильность актива).
- Хотим **восстановить неизвестные параметры и функции** так, чтобы получившееся уравнение удовлетворяло нашему набору измерений.

Такую задачу почти никогда нельзя решить численными методами!



Backward PINN: Лосс

Архитектуру будем использовать ту же. Лосс теперь выглядит так

$$\mathcal{L}_{\text{Total}} = \underbrace{\mathcal{L}_{\text{PDE}}}_{\text{дифф. уравнения}} + \underbrace{\mathcal{L}_{\text{Data}}}_{\text{удовл. данным}} \quad (12)$$



Backward PINN: Лосс

Архитектуру будем использовать ту же. Лосс теперь выглядит так

$$\mathcal{L}_{\text{Total}} = \underbrace{\mathcal{L}_{\text{PDE}}}_{\text{дифф. уравнения}} + \underbrace{\mathcal{L}_{\text{Data}}}_{\text{удовл. данным}} \quad (12)$$

Убрали слагаемые с начальным и граничными условиями и добавили слагаемое для соотносимости с данными (supervised learning)

$$\mathcal{L}_{\text{Data}} = \text{MSE} [\text{NN}(x,t), u(x,t)] \quad (13)$$



Backward PINN: Лосс

Архитектуру будем использовать ту же. Лосс теперь выглядит так

$$\mathcal{L}_{\text{Total}} = \underbrace{\mathcal{L}_{\text{PDE}}}_{\text{дифф. уравнения}} + \underbrace{\mathcal{L}_{\text{Data}}}_{\text{удовл. данным}} \quad (12)$$

Убрали слагаемые с начальным и граничными условиями и добавили слагаемое для соотносимости с данными (supervised learning)

$$\mathcal{L}_{\text{Data}} = \text{MSE} [\text{NN}(x,t), u(x,t)] \quad (13)$$


Ищем теперь функцию или скаляр, который входит в уравнение. Например, пусть для уравнения Бюргерса

$$\frac{\partial u(x,t)}{\partial t} + u(x,t) \frac{\partial u(x,t)}{\partial x} - \nu \frac{\partial^2 u(x,t)}{\partial x^2} = 0 \quad (14)$$

мы хотим найти параметр ν . Тогда, обновляя параметр градиентным спуском, backward торча будет считать производную лосса по ν .



Backward PINN: примеры




Correct PDE	$u_t + uu_x + 0.0025u_{xxx} = 0$
Identified PDE (clean data)	$u_t + 1.000uu_x + 0.0025002u_{xxx} = 0$
Identified PDE (1% noise)	$u_t + 0.999uu_x + 0.0024996u_{xxx} = 0$

Рис.: Уравнение Кортевега — де Фриза. Решена обратная задача, восстановлены скалярные коэффициенты перед слагаемыми.



Backward PINN: примеры



Correct PDE	$u_t + (uu_x + vu_y) = -p_x + 0.01(u_{xx} + u_{yy})$ $v_t + (uv_x + vv_y) = -p_y + 0.01(v_{xx} + v_{yy})$
Identified PDE (clean data)	$u_t + 0.999(uu_x + vu_y) = -p_x + 0.01047(u_{xx} + u_{yy})$ $v_t + 0.999(uv_x + vv_y) = -p_y + 0.01047(v_{xx} + v_{yy})$
Identified PDE (1% noise)	$u_t + 0.998(uu_x + vu_y) = -p_x + 0.01057(u_{xx} + u_{yy})$ $v_t + 0.998(uv_x + vv_y) = -p_y + 0.01057(v_{xx} + v_{yy})$

Рис.: Уравнение Навье-Стокса. Решена обратная задача, восстановлены скалярные коэффициенты перед слагаемыми и градиент поля давления p_x, p_y .



Преимущества и проблемы PINN

Преимущества



Преимущества и проблемы PINN

Преимущества

- PINN используют знания о физике процесса, никто не запрещает использовать классические постановки supervised learning и добавить в лосс PI часть.



Преимущества и проблемы PINN

Преимущества

- PINN **используют знания о физике процесса**, никто не запрещает использовать классические постановки supervised learning и добавить в лосс PI часть.
- PINN **умеют решать обратные задачи**, чего не умеют делать численные методы.



Преимущества и проблемы PINN

Преимущества

- PINN **используют знания о физике процесса**, никто не запрещает использовать классические постановки supervised learning и добавить в лосс PI часть.
- PINN **умеют решать обратные задачи**, чего не умеют делать численные методы.
- PINN **легко масштабируются и обобщаются**, можно использовать почти любую архитектуру нейронной сети.



Преимущества и проблемы PINN

Недостатки

Преимущества

- PINN **используют знания о физике процесса**, никто не запрещает использовать классические постановки supervised learning и добавить в лосс PI часть.
- PINN **умеют решать обратные задачи**, чего не умеют делать численные методы.
- PINN **легко масштабируются и обобщаются**, можно использовать почти любую архитектуру нейронной сети.



Преимущества и проблемы PINN

Преимущества

- PINN **используют знания о физике процесса**, никто не запрещает использовать классические постановки supervised learning и добавить в лосс PI часть.
- PINN **умеют решать обратные задачи**, чего не умеют делать численные методы.
- PINN **легко масштабируются и обобщаются**, можно использовать почти любую архитектуру нейронной сети.

Недостатки

- Пока что PINN **в прямых задачах работают хуже**, чем продвинутые численные методы.



Преимущества и проблемы PINN

Преимущества

- PINN **используют знания о физике процесса**, никто не запрещает использовать классические постановки supervised learning и добавить в лосс PI часть.
- PINN **умеют решать обратные задачи**, чего не умеют делать численные методы.
- PINN **легко масштабируются и обобщаются**, можно использовать почти любую архитектуру нейронной сети.

Недостатки

- Пока что PINN **в прямых задачах работают хуже**, чем продвинутые численные методы.
- **Нет строгих априорных оценок ошибки** как в классических численных методах



Преимущества и проблемы PINN

Преимущества

- PINN **используют знания о физике процесса**, никто не запрещает использовать классические постановки supervised learning и добавить в лосс PI часть.
- PINN **умеют решать обратные задачи**, чего не умеют делать численные методы.
- PINN **легко масштабируются и обобщаются**, можно использовать почти любую архитектуру нейронной сети.

Недостатки

- Пока что PINN **в прямых задачах работают хуже**, чем продвинутые численные методы.
- **Нет строгих априорных оценок ошибки** как в классических численных методах
- Нужно **много времени для обучения**. Решать PDE численно обычно на несколько порядков быстрее.



Преимущества и проблемы PINN

Преимущества

- PINN **используют знания о физике процесса**, никто не запрещает использовать классические постановки supervised learning и добавить в лосс PI часть.
- PINN **умеют решать обратные задачи**, чего не умеют делать численные методы.
- PINN **легко масштабируются и обобщаются**, можно использовать почти любую архитектуру нейронной сети.

Недостатки

- Пока что PINN **в прямых задачах работают хуже**, чем продвинутые численные методы.
- **Нет строгих априорных оценок ошибки** как в классических численных методах
- Нужно **много времени для обучения**. Решать PDE численно обычно на несколько порядков быстрее.
- ALARM: **проблемы со сходимостью**. Наличие нескольких слагаемых в лоссе делает перекосы в обучении. PINN очень капризные относительно выбора оптимизатора, функций активации, и т.д.



Еще немного про сходимость

Часто для PINN используют **методы оптимизации старше первого порядка**, так как гиперповерхность Лосса в пространстве параметров может быть очень сложной из-за уравнений.




Еще немного про сходимость

Часто для PINN используют **методы оптимизации старше первого порядка**, так как гиперповерхность Лосса в пространстве параметров может быть очень сложной из-за уравнений.

$$\frac{\partial u}{\partial t} + \beta \frac{\partial u}{\partial x} = 0, \quad x \in \Omega, \quad t \in [0, T],$$

$$u(x, 0) = h(x), \quad x \in \Omega.$$



β	1	10	20	30	40
Relative error	7.84×10^{-3}	1.08×10^{-2}	7.50×10^{-1}	8.97×10^{-1}	9.61×10^{-1}
Absolute error	3.17×10^{-3}	6.03×10^{-3}	4.32×10^{-1}	5.42×10^{-1}	5.82×10^{-1}

Рис.: Сложность пространства лосса в зависимости от параметра уравнения. Резкие пики могут сильно ухудшить сходимость сети.



Спасибо за внимание!