

Введение в NLP и трансформерные модели



Привет!

Я Мария Тихонова

Кандидат компьютерных наук

Закончила МГУ и ШАД

Руководитель исследовательского кластера в 

Доцент 

Руководитель курсов по LLM   U S



Давайте познакомимся

С какого вы факультета?

Есть ли у вас опыт, связанный IT?

С какой основной целью пришли сегодня?


Что такое Natural Language Processing?



Что такое Natural Language Processing?

Natural Language Processing (NLP)
обработка естественного языка —
раздел Data Science, посвященный тому,
как компьютеры анализируют
естественный (человеческий) язык.

NLP позволяет применять алгоритмы
машинного обучения для текста.



Где используется NLP?



Где используется NLP?

- Информационный поиск (Google, Yandex, etc.)
- Автоматизация обработки обращений
- Автоматизация документооборота
- Машинный перевод
- Чат-боты
- Генерация текстов
- Виртуальные ассистенты и т. д.

Три основных типа NLP задач

1) классификация/кластеризация текстов

текст → метка, несколько меток



Три основных типа NLP задач

1) классификация/кластеризация текстов

текст → метка, несколько меток

2) классификация последовательности
(sequence labeling)

каждое слово в тексте → метка



Три основных типа NLP задач

1) классификация/кластеризация текстов

текст → метка, несколько меток

2) классификация последовательности
(sequence labeling)

каждое слово в тексте → метка

3) sequence to sequence (seq2seq)

текст → текст



Три основных типа NLP задач

1) классификация/кластеризация текстов

текст → метка, несколько меток

2) классификация последовательности
(sequence labeling)

каждое слово в тексте → метка

3) sequence to sequence (seq2seq)

текст → текст

+ Иногда требуется:


текст → число и текст → расстояние до других текстов



Классификация и кластеризация текстов

Классификация

- Фильтрация спама
- Анализ тональности
- Жанр



Кластеризация



WORLD

Israeli military says it is widening attacks on militant targets in Gaza amid continuing terrorist rocket attacks




POLITICS

Kamala Harris has gone 56 days without a news conference since being tapped for border crisis role




ENTERTAINMENT

Demi Lovato comes out as non-binary



Sequence Labeling

POS-Tagging – разметка по частям речи





NER – распознавание именованных сущностей

Взыскать с Общества с ограниченной ответственностью «Комбинат питания Бутраша» в пользу Индивидуального предпринимателя Бугатовой Алёны Александровны денежные средства в размере 16682 руб. 91 коп., в том числе 16085 руб. 75 коп. долга и 597 руб. 16 коп. процентов за пользование чужими денежными средствами, а также 2000 руб. 00 коп. в возмещение расходов по уплате государственной пошлины.

```
{
  "paying": {
    "type": "ООО",
    "name": "Комбинат
питания Бутраша"
  },
  "receiving": {
    "type": "ИП",
    "name": {
      "first": "Алёна",
      "middle":
"Александровна",
      "last": "Бугатова"
    }
  },
  "penalties": [
    16085.75,
    597.16,
    2000
  ]
}
```

Seq2seq

- Машинный перевод
- Вопросно-ответные системы
- Парафраз текста
- Суммаризация текста
- Чат-боты *и многое другое*



Генерация текстов

GPT-5.2

Claude

DeepSeek

GigaChat etc.



Каковы основные пути развития искусственного интеллекта в области медицины?



Существует несколько путей развития искусственного интеллекта в области медицины, включая:


1. Использование машинного обучения для анализа медицинских данных, таких как изображения, лабораторные тесты и электрокардиограммы, чтобы обнаруживать болезни и подбирать наиболее эффективные способы лечения.
2. Использование навыков естественного языка для создания чат-ботов и виртуальных медицинских помощников, которые могут отвечать на вопросы пациента в любое время суток.



Придумай слоган для компании, занимающейся выпуском бензопил для сотрудников ИТ компаний



"Бензопила от нашей компании – ваши сотрудники пилят код в два раза быстрее!"



Расскажи анекдот про машинное обучение



Есть такой анекдот: приходит парень к психологу и говорит:

— Доктор, у меня проблема! Я не могу перестать думать о машинном обучении! Мне даже снится как я обучаю модели и анализирую данные!

Психолог говорит:




— Не беспокойтесь, это нормально. Ведь вы робот.

Новая эра

Большие языковые модели = Large Language Models = LLMs (ChatGPT, GigaChat, DeepSeek) открыли новые горизонты в области NLP и повлияли на нас во всем.

Облегчают труд в самых разных сферах:

- **написание текста/переписывание текста в нужном стиле/шаблоне**
- **поиск необходимой информации**
- **быстрая суммаризация информации**
- **написание программного кода**
- **создание презентаций**



AI повсюду

Copilot
Cursor

```
GITHUB COPILOT: CHAT

monalisa
Write unit tests for this function

GitHub Copilot

import unittest
import datetime

class TestParseExpenses(unittest.TestCase):
    def test_parse_expenses_with_valid_input(self):
        expenses_string = '2023-01-02 -34.01 USD\n2023-01-03 -12.50 USD'
        expected_output = [(datetime.datetime(2023, 1, 2), -34.01, 'USD'),
                           (datetime.datetime(2023, 1, 3), -12.50, 'USD')]
        self.assertEqual(parse_expenses(expenses_string), expected_output)

    def test_parse_expenses_with_empty_input(self):
        expenses_string = ''
        expected_output = []
        self.assertEqual(parse_expenses(expenses_string), expected_output)

if __name__ == '__main__':
```




DeepSeek-R1 is now live and open source, rivaling OpenAI's Model o1. Available on web, app, and API. Click for

deepseek

Into the unknown




Сотни приложений в GPT Store




Этапы развития ИИ на пути к AGI

(от компании OpenAI, июль 2024)



Классические методы NLP

Векторные
представления слов




Откуда ноги растут?

Как компьютеру работать со словами?

Занумеровать по порядку? - Неудобно!

Идея: Представлять слова в виде векторов!




**Зачем это нужно,
если есть трансформеры и LLMs?**
(GPT-5.2, GigaChat и другие)



Векторные представления

Векторное представление — сопоставление произвольному объекту некоторого числового вектора в пространстве фиксированной размерности.

*Векторные представления можно строить для любого множества



Векторные представления
для множества героев «Кунг-фу Панда»

Векторные представления

Векторное представление - сопоставление произвольному объекту некоторого числового вектора в пространстве фиксированной размерности.


Наиболее известный вид – **векторные представления слов (word embedding)**.

Векторы могут обладать разнообразными полезными свойствами, отражать близость объектов в разных смыслах.

Для слов это может быть семантическая близость.

Популярные алгоритмы: Word2Vec, FastText

**Векторные представления можно строить для любого множества*





Векторные представления для множества героев «Кунг-фу Панда»

Word2Vec

Алгоритм Word2Vec, который позволил строить семантически и синтаксические богатые вектора.

Магия: эти вектора можно было складывать, вычитать и получать что-то осмысленное в пространстве слов!



Mikolov, K. Chen, G. Corrado, J. Dean.

Efficient Estimation of Word Representations in Vector Space (2013)

T. Mikolov, I. Sutskever, K. Chen, G. Corrado, J. Dean.

Distributed Representations of Words and Phrases and their Compositionality (2013).

А что если у нас тексты?

Идея

для текста можно как-то усреднить вектора входящих в него слов



Представили каждый текст в виде вектора,
который можно рассматривать как набор признаков



Можем применять методы классического ML.

Например: Градиентный Бустинг для задач классификации текстов.


Результат

с помощью векторных представлений научились решать очень большое количество разнообразных NLP задач.



Языковые модели

Language Models = LMs





*Пока просто, не LLMs

Языковое моделирование (Language Modeling)

Что означает «моделировать что-то»?

Языковые модели (Language Models или LMs) способны оценивать вероятность разных языковых единиц (токенов):

- СИМВОЛОВ,
- СЛОВ,
- последовательностей слов,
- и т. д.



Языковое моделирование (Language Modeling)

- Мы не знаем истинные вероятности предложения
(= *последовательности слов*).
- Но мы можем обучить **языковую модель оценивать** эти вероятности и предсказывать вероятность следующего слова.
- Обучаем модель на корпусе текстов, чтобы она могла оценить вероятность следующего слова в предложении.

Языковое моделирование (Language Modeling)

Задача языкового моделирования

предсказать вероятность следующего слова в последовательности

$$P(w_n | w_{n-1}, w_{n-2}, \dots, w_1)$$



Да-да! Старый добрый T9 это, по сути, языковая модель!

Языковое моделирование (Language Modeling)


Типы языковых моделей:

- **Count-based Models** (Statistical) – основаны на статистических методах.
- **Neural Language Models** – нейросетевые модели!

*Сегодня рулят
БОЛЬШИЕ ТРАНСФОРМЕРНЫЕ модели!




Нейросетевые LMs



*Пока просто, не LLMs

Основная концепция языковой модели




По контексту слова до i -го включительно хотим получить вероятностное распределение для $(i+1)$ -ого слова.

Слова подаем в виде векторов:

- используем готовые предобученные вектора,
- выучиваем вектора в процессе обучения нейросети.

Обучение и генерация



Teacher forcing: Во время обучения подаем на следующем шаге реальное продолжение текста, независимо от того, какое слово сеть предскажет на каждом шаге.

Without teacher forcing: Для генерации текста сгенерированное на выходе сети слово идет на вход сети на следующем шаге.

Обучение: Loss = функция потерь

Перекрёстная энтропия (Cross-Entropy)

$$L_{CE} = - \sum_{i=1}^n t_i \log(p_i), \text{ for } n \text{ classes,}$$

where t_i is the truth label and p_i is the Softmax probability for the i^{th} class.


Хотим чтобы модель предсказала слово cat

Training example: I saw a **cat** on a mat <eos>


Model prediction: $p(* | \text{I saw a})$

Target


Loss = $-\log(p(\text{cat})) \rightarrow \min$



Language Model: все вместе



Recap: softmax



Преобразует набор чисел в вероятностное распределение с сохранением порядка.

Стратегии генерации текста




Как теперь генерировать текст?

На каждом шаге предсказываем вероятностное распределение следующего слова.

Но нам нужно сгенерировать (= написать)
конкретное слово! Как быть?

Первое, что приходит на ум - **на каждом шаге
выбирать самое вероятное слово.**




Жадное декодирование (Greedy Decoding)

Идея:

на каждом шаге
выбираем самое вероятное слово

В чем проблема?



Жадное декодирование (Greedy Decoding)


Идея:

на каждом шаге
выбираем самое вероятное слово

В чем проблема?


Проблемы:

- лучший вариант на каждом шаге $\neq$ лучший перевод,
- нет возможности изменить что-то в прошлом.



Лучевой поиск (Beam search)

Следим за n лучами – наиболее вероятными гипотезами (4-10).
На каждом шаге оставляем n наиболее вероятных вариантов.




Вопрос:

как добавить случайности в генерацию
(например, для вариативности)?

Сэмплирование (Sampling)

Вопрос: как добавить случайности в генерацию?

- **Ответ:** на каждом шаге случайным образом выбирать одно из наиболее вероятных слов (с учетом вероятностей этих слов).



Революция трансформеров




Трансформер

Сегодня почти все NLP задачи можно решить с помощью языковых моделей



Стандартом в области языкового моделирования является архитектура трансформер

Оригинальная архитектура трансформер была предложена для задачи машинного перевода




Архитектура Encoder-Decoder

Encoder (кодировщик)


читает последовательность на языке оригинала

Decoder (декодировщик)


используя информацию из кодировщика и историю предсказывает вероятностное распределение следующего слова



Language Model VS Encoder-Decoder




VS





Трансформер: high-level

Ключевым элементом трансформера является **механизм внимания** (self-attention).




Механизм внимания

Механизм внимания имитирует внимание человека при чтении текста, позволяя **фокусироваться** на важных для понимания текущего слова контекстных словах.



Зоопарк трансформерных моделей



Transformer Family Tree


Дообучение предобученных моделей (Pretraining + fine-tuning)

Дообучение предобученных моделей

Предобучение (Pretrain)

- Предобучить модель на задачу языкового моделирования
- Обучить модель языку на огромном корпусе неразмеченных текстов
- Сохранить параметры модели

text is here for LM</eos>




Some text is here for LM

Дообучение предобученных моделей

Дообучение (Fine-tune)

- Взять предобученную модель.
- Дообучить под конкретную задачу на небольшом объеме данных.
- Получить высокий результат благодаря знаниям модели, полученным на этапе предобучения.



BERT = **B**idirectional *E*ncoder **R**epresentations from **T**ransformers

BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding

Jacob Devlin Ming-Wei Chang Kenton Lee Kristina Toutanova

Google AI Language

`{jacobdevlin, mingweichang, kentonl, kristout}@google.com`



BERT побеждает всех!

System	MNLI-(m/mm) 392k	QQP 363k	QNLI 108k	SST-2 67k	CoLA 8.5k	STS-B 5.7k	MRPC 3.5k	RTE 2.5k	Average -
Pre-OpenAI SOTA	80.6/80.1	66.1	82.3	93.2	35.0	81.0	86.0	61.7	74.0
BiLSTM+ELMo+Attn	76.4/76.1	64.8	79.9	90.4	36.0	73.3	84.9	56.8	71.0
OpenAI GPT	82.1/81.4	70.3	88.1	91.3	45.4	80.0	82.3	56.0	75.2
BERT _{BASE}	84.6/83.4	71.2	90.1	93.5	52.1	85.8	88.9	66.4	79.6
BERT _{LARGE}	86.7/85.9	72.1	91.1	94.9	60.5	86.5	89.3	70.1	81.9

MultiNLI

Premise: Hills and mountains are especially sanctified in Jainism.

Hypothesis: Jainism hates nature.

Label: Contradiction

CoLa

Sentence: The wagon rumbled down the road.

Label: Acceptable

Sentence: The car honked down the road.

Label: Unacceptable



Генеративные модели aka GPTs



Генеративные модели

Основная идея

- *Предобучить большой трансформерный декодер на задачу языкового моделирования.*
- *Сформулировать задачу NLP как задачу продолжения текста.*
- *Использовать GPT модель без дополнительного дообучения (или с небольшим дообучением).*

Генеративные модели

- *Language Models are Few-Shot Learners, Brown et al, 2020*
- ОООООчень большая: **училась на 570GB текстов,**
размер - **175B parameters (!!!)**

1) Переформулируем задание в виде инструкции (промпта) на естественном языке.

2) Применяем модель к задаче без дообучения, показывая ей отдельные примеры-образцы.

Zero-shot

The model predicts the answer given only a natural language description of the task. No gradient updates are performed.

```
1 Translate English to French: ← task description
2 cheese => ..... ← prompt
```

Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.

```
1 Translate English to French: ← task description
2 sea otter => loutre de mer ← examples
3 peppermint => menthe poivrée ←
4 plush girafe => girafe peluche ←
5 cheese => ..... ← prompt
```

Обучение на инструкциях

Основная идея

задача языкового моделирования несогласована (*misaligned*) с тем, что ждут люди от языковых моделей.

Мы хотим, чтобы модель понимала наши намерения и следовала инструкциям, а не просто предсказывала самое вероятное слово.

Prompt:

What is the purpose of the list C in the code below?

```
def binomial_coefficient(n, r):  
    C = [0 for i in range(r + 1)];  
    C[0] = 1;  
    for i in range(1, n + 1):  
        j = min(i, r);  
        while j > 0:  
            C[j] += C[j - 1];  
            j -= 1;  
    return C[r]
```

GPT-3 175B completion:

- A. to store the value of C[0]
- B. to store the value of C[1]
- C. to store the value of C[i]
- D. to store the value of C[i - 1]

InstructGPT 175B completion:


The list C in this code is used to store the values of the binomial coefficient as the function iterates through the values of n and r. It is used to calculate the value of the binomial coefficient for a given value of n and r, and stores the result in the final return value of the function.

Обучение на инструкциях


Step 1

Collect demonstration data,
and train a supervised policy.


A prompt is
sampled from our
prompt dataset.



A labeler
demonstrates the
desired output
behavior.



This data is used
to fine-tune GPT-3
with supervised
learning.



- Ручная разметка качественного и разнообразного инструктивного датасета
- Большая доля ручного труда
- Высокое требование к качеству инструкций
- Дообучаем модель **на качественном датасете**

Table 1: Distribution of use case categories from our API prompt dataset.

Use-case	(%)
Generation	45.6%
Open QA	12.4%
Brainstorming	11.2%
Chat	8.4%
Rewrite	6.6%
Summarization	4.2%
Classification	3.5%
Other	3.5%
Closed QA	2.6%
Extract	1.9%

Table 2: Illustrative prompts from our API prompt dataset. These are fictional examples inspired by real usage—see more examples in Appendix A.2.1.

Use-case	Prompt
Brainstorming	List five ideas for how to regain enthusiasm for my career
Generation	Write a short story where a bear goes to the beach, makes friends with a seal, and then returns home.
Rewrite	This is the summary of a Broadway play: "" {summary} "" This is the outline of the commercial for that play: ""

Результаты

Prompt:

What is the purpose of the list C in the code below?

```
def binomial_coefficient(n, r):  
    C = [0 for i in range(r + 1)];  
    C[0] = 1;  
    for i in range(1, n + 1):  
        j = min(i, r);  
        while j > 0:  
            C[j] += C[j - 1];  
            j -= 1;  
    return C[r]
```

GPT-3 175B completion:

- A. to store the value of C[0]
- B. to store the value of C[1]
- C. to store the value of C[i]
- D. to store the value of C[i - 1]

InstructGPT 175B completion:

The list C in this code is used to store the values of the binomial coefficient as the function iterates through the values of n and r. It is used to calculate the value of the binomial coefficient for a given value of n and r, and stores the result in the final return value of the function.

GigaChat & DeepSeek & GPT-5.2 & etc.



Каковы основные пути развития искусственного интеллекта в области медицины?



Существует несколько путей развития искусственного интеллекта в области медицины, включая:


1. Использование машинного обучения для анализа медицинских данных, таких как изображения, лабораторные тесты и электрокардиограммы, чтобы обнаруживать болезни и подбирать наиболее эффективные способы лечения.
2. Использование навыков естественного языка для создания чат-ботов и виртуальных медицинских помощников, которые могут отвечать на вопросы пациента в любое время суток.



Придумай слоган для компании, занимающейся выпуском бензопил для сотрудников ИТ компаний



"Бензопила от нашей компании – ваши сотрудники пилят код в два раза быстрее!"



Расскажи анекдот про машинное обучение



Есть такой анекдот: приходит парень к психологу и говорит:

— Доктор, у меня проблема! Я не могу перестать думать о машинном обучении! Мне даже снится как я обучаю модели и анализирую данные!

Психолог говорит:

— Не беспокойтесь, это нормально. Ведь вы робот.

Особенности работы LLM

**Генеративная модель –
не база данных /
поисковый движок**

Модель не «знает» ответ, то есть не
выдаёт готовый
и заранее определённый результат

Модель «достраивает» ответ по контексту,
«угадывая» наиболее вероятное
продолжение диалога на основании
предыдущих реплик и тех данных, на
которых шло обучение

**Генеративные модели
галлюцинируют
фантазируют**

Принять как риск / учить модель /
строить архитектуру,
минимизирующую вероятность
галлюцинаций

...и не калькулятор

Для решения узкоспециализированных
задач лучше использовать узких
специалистов (специализированные модели,
функции и пр.)

Задача LLM – понять, где требуется помощь
такого специалиста, и «обратиться» за ней

Какой вопрос – такой ответ

Правильно сформулировать
запрос - половина успеха

7 правил составления хороших промптов

1) Не пишите «по-дружески»

Сразу переходите к делу — без приветствий и вежливых фраз. Лучше чётко сформулируйте ТЗ: цель, формат и объём текста.

7 правил составления хороших промптов

1) Не пишите «по-дружески»

Сразу переходите к делу — без приветствий и вежливых фраз. Лучше чётко сформулируйте ТЗ: цель, формат и объём текста.

2) Не забывайте про роль (System Prompt) и контекст

Для точного ответа задайте для AI роль: «Ты — маркетолог», «Ты — юрист».

7 правил составления хороших промптов

1) Не пишите «по-дружески»

Сразу переходите к делу — без приветствий и вежливых фраз. Лучше чётко сформулируйте ТЗ: цель, формат и объём текста.

2) Не забывайте про роль (System Prompt) и контекст

Для точного ответа задайте для AI роль: «Ты — маркетолог», «Ты — юрист».

3) Разбивайте сложные задачи на этапы

Это поможет AI точнее понять цель и выдать качественный результат.

7 правил составления хороших промптов

1) Не пишите «по-дружески»

Сразу переходите к делу — без приветствий и вежливых фраз. Лучше чётко сформулируйте ТЗ: цель, формат и объём текста.

2) Не забывайте про роль (System Prompt) и контекст

Для точного ответа задайте для AI роль: «Ты — маркетолог», «Ты — юрист».

3) Разбивайте сложные задачи на этапы

Это поможет AI точнее понять цель и выдать качественный результат.

4) Пишите максимально конкретно

Вместо «сделай хорошо/правильно» — уточните, что значит «хорошо/правильно» именно для вас. Идеально, если вы сможете подкрепить запрос примерами.

7 правил составления хороших промптов

1) Не пишите «по-дружески»

Сразу переходите к делу — без приветствий и вежливых фраз. Лучше чётко сформулируйте ТЗ: цель, формат и объём текста.

2) Не забывайте про роль (System Prompt) и контекст

Для точного ответа задайте для AI роль: «Ты — маркетолог», «Ты — юрист».

3) Разбивайте сложные задачи на этапы

Это поможет AI точнее понять цель и выдать качественный результат.

4) Пишите максимально конкретно

Вместо «сделай хорошо/правильно» — уточните, что значит «хорошо/правильно» именно для вас. Идеально, если вы сможете подкрепить запрос примерами.

5) Экспериментируйте с формулировками

Экспериментируйте с запросами и пробуйте разные формулировки для каждой задачи

7 правил составления хороших промптов

1) Не пишите «по-дружески»

Сразу переходите к делу — без приветствий и вежливых фраз. Лучше чётко сформулируйте ТЗ: цель, формат и объём текста.

2) Не забывайте про роль (System Prompt) и контекст

Для точного ответа задайте для AI роль: «Ты — маркетолог», «Ты — юрист».

3) Разбивайте сложные задачи на этапы

Это поможет AI точнее понять цель и выдать качественный результат.

4) Пишите максимально конкретно

Вместо «сделай хорошо/правильно» — уточните, что значит «хорошо/правильно» именно для вас. Идеально, если вы сможете подкрепить запрос примерами.

5) Экспериментируйте с формулировками

Экспериментируйте с запросами и пробуйте разные формулировки для каждой задачи

6) Не используйте AI как хранилище

Всю важную информацию сохраняйте в специально предназначенных местах.

7 правил составления хороших промптов

1) Не пишите «по-дружески»

Сразу переходите к делу — без приветствий и вежливых фраз. Лучше чётко сформулируйте ТЗ: цель, формат и объём текста.

2) Не забывайте про роль (System Prompt) и контекст

Для точного ответа задайте для AI роль: «Ты — маркетолог», «Ты — юрист».

3) Разбивайте сложные задачи на этапы

Это поможет AI точнее понять цель и выдать качественный результат.

4) Пишите максимально конкретно

Вместо «сделай хорошо/правильно» — уточните, что значит «хорошо/правильно» именно для вас. Идеально, если вы сможете подкрепить запрос примерами.

5) Экспериментируйте с формулировками

Экспериментируйте с запросами и пробуйте разные формулировки для каждой задачи

6) Не используйте AI как хранилище

Всю важную информацию сохраняйте в специально предназначенных местах.

7) Вовремя обновляйте диалог

Если задача меняется, напишите об этом прямым текстом. Ещё лучше создать новый диалог, чтобы обновить контекст.

Дообучение модели через адаптеры

Вопрос: А что делать если все же нужно дообучать?

Сложность: Дообучать всю модель целиком дорого.

Решение: Дообучать внешний модуль — адаптер.


Дообучение модели через адаптеры

LoRA (Low-Rank Adaptation) — это метод дообучения больших языковых моделей (LLM) без обновления всех параметров.

Оригинальные веса модели замораживаются.

В каждый слой вставляются две маленькие матрицы A и B (ранг $r \ll$ исходного W).


В обучение вовлекается только эти матрицы A и B, а итоговые веса модели $= W_0 + B \cdot A$



Борьба с галлюцинациями

Проблема: большие языковые модели (LLM) склонны к галлюцинациям и выдумкам

Очевидная идея: дать модели возможность "искать" фактическую информацию в некоторой базе



Решение: генерация с дополнением извлечением (Retrieval-Augmented Generation, RAG)

Ключевая идея: предоставить LLM доступ к **внешней базе знаний**

Зачем нужен RAG?

Проблемы LLM:

- Склонны к **галлюцинациям** — могут генерировать вводящую в заблуждение информацию.
- Опираются на **устаревшие данные** из обучающей выборки.
- **Неэффективны при работе с узкоспецифичными знаниями.**
- Недостаточная **глубина в специализированных областях.**

Как RAG улучшает работу LLM?

Улучшает **точность** и **релевантность** за счёт использования фактологически точной **опоры на источник**.



RAG vs метод "Search"

🌐 Искать в сети



Что делает search?

- Выполняет **реальный онлайн-поиск** (например, через Bing или другой поисковик).
- Возвращает ссылки и текстовые сниппеты с сайтов.
- LLM "читает" эти страницы и **использую информацию для ответа.**


Это ближе к **tool-augmented generation** или **web-enhanced LLM**, но не **RAG** в классическом смысле.



А что делает RAG?

- **Извлечение (retrieval)** из **локального хранилища** документов, чаще всего с векторным поиском.
- **Генерация (generation)** на основе этих извлечённых документов.
- Всё это происходит **внутри системы, без выхода в интернет.**


Составляющие RAG



В качестве источников знаний могут быть:

- Структурированные и не очень БД
- Текстовые документы: pdf, doc, txt, json и др.
- Картинки и видео/аудио файлы
- Web поиск: google, yandex, bing ...

Составляющие RAG



В качестве моделей можно взять:

- OpenAI или Google решения по API
- Открытые решения LLM: DeepSeek, LLAMA, Qwen
- Пусть “сильных” - делать свое ;)

LLM для своих задач

С чего начать?

1) **Здравый смысл и валидация гипотезы**

«Действительно ли для этой задачи можно и нужно использовать LLM и агент ли это?»

2) **Первичная проверка гипотезы**

Пробуем модель «из коробки», пробуем другие модели

3) **Проработка и построение модели**

- ✓ *Строим pipeline*
- ✓ *Подбираем промпты (PlayGround)*
- ✓ *Регистрируем функции*
- ✓ *Подключаем RAG*
- ✓ *Готовим тестовый set*
- ✓ *Замеряем качество*



Ограничения и риски

- **Качество данных:** ограниченное количество качественных обучающих данных может ухудшить результаты моделей.
- **Этические вопросы:** использование ИИ для генерации текста вызывает вопросы о плагиате, предвзятости и достоверности информации.
- **Персонализация:** создание персонализированных моделей может привести к рискам, связанным с имитацией личности и нарушением конфиденциальности.

Тренды

- **Мультимодальность:** интеграция текста с другими типами данных, такими как изображения и аудио, становится всё более распространённой.
- **Локализация:** разработка моделей, способных учитывать культурные и языковые особенности различных регионов.
- **Интеграция в бизнес-процессы:** использование ИИ для автоматизации задач в маркетинге, обслуживании клиентов и других областях.



ANY
QUESTIONS
?