

NLP-2: Retrieval Augmented Generation (RAG)

Мурат Хажгериев

Содержание


- Ресар
- Плотные (Dense) vs. Разреженные (Sparse) эмбединги
- Строим RAG пайплайн
- Как я могу этому доверять?

Содержание

- **Ресар**
- Плотные (Dense) vs. Разреженные (Sparse) эмбединги
- Строим RAG пайплайн
- Как я могу этому доверять?


Возможности отдельной модели сильно ограничены обучающими данными и архитектурой

Вопрос клиента: «Каковы условия
досрочного погашения
потребительского кредита?»




Возможности отдельной модели сильно ограничены обучающими данными и архитектурой

Вопрос клиента: «Каковы условия досрочного погашения потребительского кредита?»




Ответ модели: «Обычно досрочное погашение кредита возможно, но может сопровождаться комиссией или ограничениями. Уточните детали в вашем банке.»


Добавление внешней базы данных позволяет качественно поменять характер модели




Добавление внешней базы данных позволяет качественно поменять характер модели



Retrieval-Augmented Generation Pipeline




RAG Pipeline: Retriever




RAG Pipeline: Retriever

Retrieval




RAG Pipeline: Generator


Generator




RAG Pipeline: собираем вместе




На практике релевантные куски данных часто еще раз реранжируются




Векторные базы данных хранят эмбединги объектов



Эмбединги генерируются, например, Encoder частью трансформера (BERT)




Мы также можем фильтровать объекты в базе данных по тегам




Мы также можем использовать графовые базы данных для обогащения знания



Устройство Graph RAG




Мы можем объединять информацию из разных типов баз данных вместе




Содержание

- Ресар
- **Плотные (Dense) vs. Разреженные (Sparse) эмбединги**
- Строим RAG пайплайн
- Как я могу этому доверять?


Энкодер генерирует контекстно-зависимые вектора для каждого входного токена




Мы можем получить вектор входной последовательности, например, агрегировав вектора-выходы энкодера




Эта модель может быть использована как генератор эмбеддингов. Пример – Bi-Encoder.



Эта модель может быть использована как генератор эмбеддингов. Пример – Bi-Encoder.



Другой подход - обрабатывать вход парами (Cross-Encoder)



Term Frequency-Inverse Document Frequency (TF-IDF)

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

$$\text{tf}(t, d) = \frac{\sum_{t \in d} t}{|d|}$$

$$\text{idf}(t, D) = 1 + \log\left(\frac{1 + |D|}{1 + \sum_{t \in D} t}\right)$$

BM25 (best matching 25)

$$\text{score}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

$$\text{IDF}(q_i) = \ln \left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1 \right)$$

BM25 (best matching 25)

$$\text{score}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

$$\text{IDF}(q_i) = \ln \left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1 \right)$$


Содержание

- Ресар
- Плотные (Dense) vs. Разреженные (Sparse) эмбединги
- **Строим RAG пайплайн**
- Как я могу этому доверять?


Hybrid search

- Reciprocal Rank Fusion: $RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$

Sort documents by score




Assign rank positions



Apply the RRF formula

$$RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$$



Add rank contributions, Return the top results

Document Number	Sum Calculation	Rank Score
Doc 1	$1/61 + 1/64 + 1/61$	0.0484
Doc 10	$1/62 + 1/61$	0.0325
Doc 11	$1/62$	0.0161
Doc 13	$1/62$	0.0161
Doc 20	$1/63$	0.0159
Doc 2	$1/63$	0.0159
Doc 25	$1/63$	0.0159
Doc 12	$1/64$	0.0156
Doc 14	$1/64$	0.0156


Hybrid search

- Reciprocal Rank Fusion: $RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$
- Cross-Encoder

Содержание

- Ресар
- Плотные (Dense) vs. Разреженные (Sparse) эмбединги
- Строим RAG пайплайн
- **Как я могу этому доверять?**

Как померить качество?



Спасибо за внимание!