

Мультимодальность

Марк Блуменау

Кто такая модальность?

В философии и лингвистике: категория возможности, долженствования или просто существования чего-л. в отношении говорящего к содержанию высказывания.

В нейронках: вид данных, который надо как-то отдельно обрабатывать

Виды

- 1) Аудио
- 2) Текст
- 3) Картинки
- 4) Видео (но может справимся делением на 1 и 3)
- 5) Графы
- 6) 3Д
- 7) ...


Почему нам не все равно?

Ваши идеи

Датасеты


- Изображения + текст: [Visual Storytelling Dataset](#), [Visual Question Answering Dataset](#), [LAION-5B Dataset](#).
- Аудио + изображения: [VGG-Sound Dataset](#), [RAVDESS Dataset](#), [Audio-Visual Identity Database \(AVID\)](#).
- Изображения + аудио + текст: [RECOLA Database](#), [IEMOCAP Dataset](#).

Объединение модальностей




Vision Language Models (VLMs)


(1) Contrastive pre-training



(2) Create dataset classifier from label text




(3) Use for zero-shot prediction




CLIP

1. Contrastive pre-training




Overview A

2. Create dataset classifier from label text



3. Use for zero-shot prediction



Overview B

Обучаем CLIP

$$\mathcal{L} = -\frac{1}{2N} \sum_{i=1}^N \left[\ln \frac{e^{v_i \cdot w_i / T}}{\sum_j e^{v_i \cdot w_j / T}} + \ln \frac{e^{w_i \cdot v_i / T}}{\sum_j e^{w_i \cdot v_j / T}} \right]$$

```
# image_encoder - ResNet or Vision Transformer
# text_encoder   - CBOW or Text Transformer
# I[n, h, w, c] - minibatch of aligned images
# T[n, l]        - minibatch of aligned texts
# W_i[d_i, d_e] - learned proj of image to embed
# W_t[d_t, d_e] - learned proj of text to embed
# t              - learned temperature parameter

# extract feature representations of each modality
I_f = image_encoder(I) #[n, d_i]
T_f = text_encoder(T)  #[n, d_t]



# joint multimodal embedding [n, d_e]
I_e = l2_normalize(np.dot(I_f, W_i), axis=1)
T_e = l2_normalize(np.dot(T_f, W_t), axis=1)

# scaled pairwise cosine similarities [n, n]
logits = np.dot(I_e, T_e.T) * np.exp(t)


# symmetric loss function
labels = np.arange(n)
loss_i = cross_entropy_loss(logits, labels, axis=0)
loss_t = cross_entropy_loss(logits, labels, axis=1)
loss   = (loss_i + loss_t)/2
```

Figure 3. Numpy-like pseudocode for the core of an implementation of CLIP.


Результаты CLIP




Гигачат имеет клип под капотом :)




BLIP




Давайте учить VLIP




Зачем оно надо?




Transformer




Cross attention



Cross attention




Cross attention




[Understanding and Coding Self-Attention.](#)
[Multi-Head Attention, Causal- Attention, and](#)
[Cross-Attention in LLMs](#)

Source: "Attention Is All You Need" (<https://arxiv.org/abs/1706.03762>)


Vision Transformer (ViT)




Transformer Encoder



CLAP



LLaVa








Source: <https://www.barnorama.com/wp-content/uploads/2016/12/03-Confusing-Pictures.jpg>


User	What is unusual about this image?
LLaVA	The unusual aspect of this image is a man ironing clothes on the back of a minivan or van. This is not a typical place to perform this activity, as one would usually iron clothes in a more stationary and safe location, such as a home, using a regular ironing board. The scene depicted in the image is peculiar as it involves a makeshift ironing setup on a vehicle, which can be both unsafe and unconventional. Additionally, it is not clear how the man is able to maintain balance and stability while ironing clothes in such an unstable environment.
User	[Start a new conversation, and clear the history]
User	What's happening in the scene?
LLaVA	The image depicts a man standing on top of a yellow SUV in a busy city street. He is holding a portable ladder, seemingly ironing clothes while standing on the vehicle. Around the scene, there are other cars, a traffic light, and a fire hydrant. Additionally, there are two other people in the vicinity, one close to the man on the car and another further away. The man on the ladder appears to be attracting attention due to his unconventional choice of ironing his clothes on top of a moving car . The city street around him is bustling with activity, adding to the unique nature of the scene.
User	What is unusual about this image?
GPT-4 [36]	The unusual thing about this image is that a man is ironing clothes on an ironing board attached to the roof of a moving taxi.
User	What is unusual about this image?
BLIP-2	a man is sitting on the back of a yellow cab
User	What is unusual about this image?
OpenFlamingo	The man is drying his clothes on the hood of his car.

Flamingo


Input Prompt						Completion
	This is a chinchilla. They are mainly found in Chile.		This is a shiba. They are very popular in Japan.		This is	→ a flamingo. They are found in the Caribbean and South America.
	What is the title of this painting? Answer: The Hallucinogenic Toreador.		Where is this painting displayed? Answer: Louvres Museum, Paris.		What is the name of the city where this was painted? Answer:	→ Arles.
	Output: "Underground"		Output: "Congress"		Output:	→ "Soulomes"
	2+1=3		5+6=11			→ 3x6=18

Архитектура





Janus Pro



Qwen 2.5 Omni

Video-Chat

Query: What did the person on the left and the person on the right say, respectively?




Response:



(The person on the left says, "Welcome everyone to the show."
The person on the right says, "I'm very happy that everyone can watch our show.")

Image-Chat


Query: Please help me solve this math problem.



Response:



(Well, since $X + Y = 10$ and $X = 2$, you can just substitute the value of X into the first equation. So it becomes $2 + Y = 10$. Then, if you subtract 2 from both sides, you get $Y = 8$. So, Y equals 8.)



Text-Chat

Query: Mother's Day is coming soon. Can you help me write a message for my mom?



Response:



("Mom, Mother's Day is almost here, and I just wanted to tell you how much you mean to me. You've always been there for me, no matter what. Your love has shaped who I am today. Thank you for everything you've done for me. I hope this Mother's Day brings you so much joy and happiness.")

Audio-Chat

Query: Please provide a brief description of this music.



Response:



(It's a pop song in A major with a 4/4 time signature. The chord progression mainly alternates between A major and D major. It has a tempo of about 90 BPM)

Домашнее задание 1

Часть первая, текстовая:

В рамках первого домашнего задания курса предлагаем Вам реализовать двух агентов:

1. ReAct-агент на LangChain – пусть он использует какие-нибудь тулзы, имеет память и решает полезную для вас микро-задачу.
2. Агент на LangGraph – пусть он обращается к какому-нибудь открытому API по вашему запросу, анализирует ответ от API и выдает пропущенные через LLM результат. Тут надо поискать открытые API и подумать, какую полезную микро-задачу будет решать агент.

Домашнее задание оформите в виде jupyter-notebook. Перед кодом для каждого агента текстом подробно опишите, для чего нужен агент, как он работает и какую задачу решает.

Домашнее задание 1


Часть вторая, мультимодальная:

Возьмите любую VLM модель на HuggingFace и помогите своим семинаристам дешифровать каракули Марка.

Дано: уникальный датасет (фото, текст) рукописного текста от Марка и других семинаристов.

Нужно: уговорить VLM модель решить задачу OCR для вас и посчитать метрику. Минимальная метрика для зачета будет опубликована чуть позже.

Что понадобится: скорее всего, понадобится поработать с квантизацией (первый семинар) и с картинкой (предобработка, ресайз)



О сколько нас откровений
Готовит провещания дух
И Онт, сн ошибок трудных
И Генни, парадоксов друг,
И Сидрай, бог изобретатель

<https://habr.com/ru/companies/smartengines/articles/504392/>

Дедлайн

Март 2026						
пн	вт	ср	чт	пт	сб	вс
						1
2	3	4	5	6	7	8
9	10	11	12	13	14	15
16	17	18	19	20	21	22
23	24	25	26	27	28	29
30	31					

Optical character recognition (OCR)?

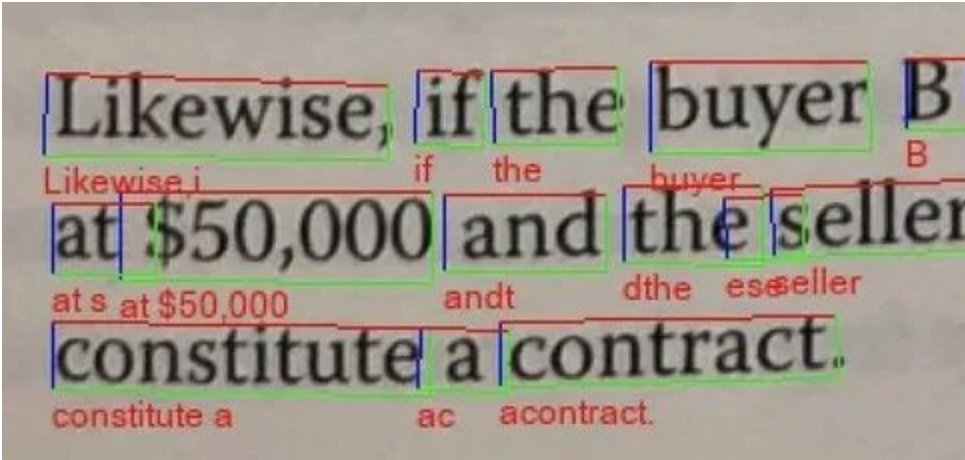





Image
pre-processing



Text Detection



Layout Analysis



Text
Recognition



Language
Model



Пример предобработки

1) Model solve?

2) Считаем градиенты по par. Зачем?
 текущие значения
 переписываем fin

3) bfloat16 $\text{gradaccum} + \text{grad}$
 + качество метрики

4) Вспомогательная ≈ 40 строк
 валидация не работает, А надо

5) model.generate
 ок

6) model
 ок

7) Бот $\approx ?$
 читать N

generate
 читать

ANSZ
 Levenshtein distance

$\text{set matrix precision}$

generate(...):
 encoder stuff
 $\text{self.decoder.generate}$

2) Model solve?

2) Считаем градиенты по par. Зачем:
тензорные ядра

3) bfloat16 перепишем fin
gradaccum + grad

4) Вспомогательная ≈ 40 строк + качество метрики

5) Валидация не работает; А надо
6) model.generate не работает

7) Бот ≈ ?
- ЧИТАТЬ N.
- Функция

10K → PIL им.
generate ЧИТАТЬ

4096
128

ANSZ
set mutual precision Levenshtein distance


generate(...):
encoder stuff
self.decoder.generate()




Как её делать?

- 1) Может её не надо делать, и вы промптами уговорите модель :)))
 - 1.1) Qwen может предпочитать промпт на китайском
- 2) OpenCV


Как это решали раньше (Tesseract)?




А если текст кривой?



CRNN для текста



TrOCR



Где это может быть полезно?

Идеи? :)

А судьи кто?

Exact match

Метрика проверяющая полное совпадения ответа и эталона.

Проблема:

«Договор действует 1 год»

≠

«Срок действия договора – год»

ANLS

Гибридная метрика для оценки последовательностей. Если ответ длиннее 5 символов, то:

$$ANLS(p, g) = \{1 - \frac{LD(p, g)}{\max(|p|, |g|)} \geq 0.5$$

В ином случае – полное вхождение ответа

Проблема:

«Трава зеленая»

= (почти)

«Трава не зеленая»

LLM as a judge

