



Прогнозирование временных рядов

Костромина Алина

Центр Практического ИИ Сбера / Sber AI Lab, ML2.0

Май 2026



Какую задачу решаем и как выстраиваем сравнение моделей?

Какие методы используем и как обрабатываем данные?

Что такое стратегии прогнозирования?

Какие выводы следует унести с собой и что еще посмотреть?

Какую задачу решаем?


Прогнозируем временной ряд — последовательность значений во времени

Рассматриваем:

- Регулярные временные ряды — с равномерными временными интервалами между точками.
- Многомерные временные ряды — состоящие из нескольких компонент.

Временные ряды могут содержать дополнительные признаки.

Задача: по заданной истории L сделать прогноз на горизонт H .



Как оценить качество прогноза?

Существует множество вариантов метрик, но нет ни одной универсальной

- Лучше использовать сразу несколько.

1 Scale-Dependent

RMSE (Rooted Mean Squared Error)

$$RMSE = \sqrt{\frac{1}{n} \sum_{t=1}^n (y_t - \hat{y}_t)^2}$$

MAE (Mean Absolute Error)

$$MAE = \frac{1}{n} \sum_{t=1}^n |y_t - \hat{y}_t|$$

MdAE (Median Absolute Error)

$$MdAE = \text{median}(|y_t - \hat{y}_t|)$$

2 Scale-Independent

MAPE (Mean Absolute Percentage Error)

$$MAPE = 100 \times \frac{1}{n} \sum_{t=1}^n \left| \frac{y_t - \hat{y}_t}{y_t} \right|$$

mSMAPE (Modified Symmetric Mean Absolute Percentage Error)

$$mSMAPE = 100 \times \frac{1}{n} \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{\frac{\max(|y_t| + |\hat{y}_t| + \varepsilon, 0.5 + \varepsilon)}{2}}$$

WAPE (Weighted Absolute Percentage Error)

$$WAPE = \frac{\sum_{t=1}^n |y_t - \hat{y}_t|}{\sum_{t=1}^n |y_t|}$$

3 Relative

RelRMSE (Relative RMSE)

$$RelRMSE = \sqrt{\frac{MSE}{MSE_{baseline}}}$$

RelMAE (Relative MAE)

$$RelMAE = \frac{MAE}{MAE_{baseline}}$$

MASE (Mean Absolute Scaled Error), **RMSSE**

$$MASE = \frac{MAE}{\frac{n}{m-s} \sum_{k=s+1}^m |y_k - y_{k-s}|}$$

$$RMSSE = \frac{MSE}{\sqrt{\frac{n}{m-s} \sum_{k=s+1}^m (y_k - y_{k-s})^2}}$$


Как оценить качество прогноза?

Не стоит забывать и об адаптации схем валидации


1 Blocked KFold



2 Rolling window



3 Expanding window



4 Holdout



Самые распространенные способы валидации на практике.

Существуют и другие (например, рандомизированные или с гэпом между train и test).



Какую задачу решаем и как выстраиваем сравнение моделей?

Какие методы используем и как обрабатываем данные?

Что такое стратегии прогнозирования?

Какие выводы следует унести с собой и что еще посмотреть?

Как получить прогноз? Классические методы

Как получить прогноз? Классические методы

Классические методы имеют ограниченные возможности, но их необходимо брать за бейзлайн


Группа	Модель	Описание
Наивные методы	Mean	Среднее значение по ряду / истории
	(Seasonal) Naive	Предыдущее значение (повторение сезонного паттерна с предыдущего периода)
Статистические методы	OLS	Линейная регрессия
	SES, ETS	Модели экспоненциального сглаживания
	Theta	Прогноз θ -линий. Победитель M3
	(S)ARIMA(X)	Seasonal (S) + Autoregressive (AR) + Integrated (I) + Moving Average (MA) + eXogenous (X)
	HarmonicRegression	Подход на основе разложения Фурье и ARMA

Что лежит между наивным и средним прогнозом?



Naive: $\hat{y}_{T+h|T} = y_T$, где $h = 1, 2, \dots, H$

Average: $\hat{y}_{T+h|T} = \frac{1}{T} \sum_{t=1}^T y_t$, где $h = 1, 2, \dots, H$

Можно ли придумать что-то лучше?



Экспорт товаров и услуг из Алжира с 1960 по 2017 год.



SES — Simple Exponential Smoothing


Naive: $\hat{y}_{T+h|T} = y_T$, где $h = 1, 2, \dots, H$

Average: $\hat{y}_{T+h|T} = \frac{1}{T} \sum_{t=1}^T y_t$, где $h = 1, 2, \dots, H$


SES: $\hat{y}_{T+1|T} = \alpha y_T + \alpha(1 - \alpha)y_{T-1} + \alpha(1 - \alpha)^2 y_{T-2} + \dots$,
Где $0 \leq \alpha \leq 1$ — параметр сглаживания.

Более свежие наблюдения
получают больший вес!

Exports: Algeria — SES, alpha = 0.2



Exports: Algeria — SES, alpha = 0.8



ETS — Error, Trend, Seasonality

ETS (A, A, A)

$$y_t = \ell_{t-1} + b_{t-1} + s_{t-m} + \varepsilon_t$$

$$\ell_t = \ell_{t-1} + b_{t-1} + \alpha \varepsilon_t$$

$$b_t = b_{t-1} + \beta \varepsilon_t$$

$$s_t = s_{t-m} + \gamma \varepsilon_t$$

где: ℓ_t — оценка уровня ряда в момент времени t ,

b_t — оценка тренда (наклона) ряда в момент времени t ,


α — параметр сглаживания уровня, $0 \leq \alpha \leq 1$,

β — параметр сглаживания тренда, $0 \leq \beta \leq 1$.

s_t — сезонная компонента в момент времени t ;

m — длина сезона (например, $m = 12$ для помесячных данных с годовой сезонностью);

γ — параметр сглаживания сезонной компоненты, $0 \leq \gamma \leq 1$.







Стационарность — постоянство свойств во времени

В узком смысле (сильная стационарность) — временной ряд $y_1 \dots, y_t$ стационарен, если для любого s совместное распределение $y_1 \dots, y_{t+s}$ не зависит от t .

В широком смысле (слабая стационарность) — временной ряд $y_1 \dots, y_t$ стационарен, если:

1. Существуют конечные матожидание $m(t)$ и дисперсия $v(t)$ в каждой точке $t \in T$.
2. $m(t) = \text{const.}$ $v(t) = \text{const.}$
3. Автоковариационная функция зависит от лага τ и не зависит от t — $\text{Cov}(y_t, y_{t+\tau}) = \gamma(\tau)$.



Тесты на стационарность

Aspect	KPSS Test	Dickey-Fuller Test
Hypothesis Tested	Null: The series is stationary.	Null: The series is non-stationary.
Alternative Hypothesis	The series is non-stationary.	The series is stationary.
Sensitivity	Detects trend stationarity issues.	Detects unit root (random walk) stationarity.
Approach	Tests for stationarity by modeling residuals.	Checks for unit roots in the series.

ADF — оцениваем регрессию на приросты и смотрим статистику при y_{t-1} (тест на единичный корень).

KPSS — суммируем остатки от регрессии на детерминированные компоненты (константа + тренд) и смотрим, насколько «уносит» частичные суммы от нуля (дисперсия == 0?).

<https://www.hse.ru/mirror/pubs/share/359311210.pdf> — подробнее про ADF & KPSS

http://www.machinelearning.ru/wiki/index.php?title=Крпмепуї_KPSS — подробнее про KPSS

Предобработка временных рядов (ч. 1)

Универсально:

- **Логарифмирование / Вох-Сох / Уео-Johnson** — стабилизируем дисперсию и мультипликативные эффекты (не всегда удастся подобрать хорошие параметры).
- **Сезонное дифференцирование** — удаляем сезонность.
- **Дифференцирование** — удаляем тренд и переходим к относительным изменениям.




Figure 8.4: Top panel: US net electricity generation (billion kWh). Other panels show the same data after transforming and differencing.

ARIMA

Как подбирать гиперпараметры:

https://docs.google.com/document/d/1wVsBkRIZbHdPMQibUoXdznrmxkSZNEVFLq9D_OzCIdA/edit?usp=sharing

AR(p) (Autoregression) - модель авторегрессии порядка p .

$$y_t = c + \phi_1 y_{t-1} + \phi_2 y_{t-2} + \dots + \phi_p y_{t-p} + \varepsilon_t$$

MA(q) (Moving average) - модель скользящего среднего порядка q :

$$y_t = c + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

Если объединим две модели, то получим **ARMA(p, q)** модель:

$$y_t = c + \sum_{i=1}^p \phi_i y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

Теоретическая мотивация: любой стационарный в широком смысле процесс можно аппроксимировать с заданной точностью, выбрав необходимые p и q .

ARIMA(p, d, q) является расширением модели ARMA на нестационарные ряды:

$$\Delta^d y_i = c + \sum_{j=1}^p \phi_j \Delta^d y_{i-j} + \varepsilon_i + \sum_{j=1}^q \theta_j \varepsilon_{i-j}$$

где d - порядок дифференцирования для приведения ряда к стационарному

SARIMA

$$y_t = c + \sum_{n=1}^p \alpha_n y_{t-n} + \sum_{n=1}^q \theta_n \epsilon_{t-n} + \sum_{n=1}^P \phi_n y_{t-sn} + \sum_{n=1}^Q \eta_n \epsilon_{t-sn} + \epsilon_t$$

SARIMA(p, d, q)(P, D, Q, s) - расширение модели ARIMA для учета сезонности:

- s - период сезонности
- P - порядок сезонной AR части
- D - порядок сезонного дифференцирования ряда
- Q - порядок сезонной MA части

SARIMA(X)

$$d_t = c + \sum_{n=1}^p \alpha_n d_{t-n} + \sum_{n=1}^q \theta_n \epsilon_{t-n} + \sum_{n=1}^r \beta_n x_{n_t} + \sum_{n=1}^P \phi_n d_{t-sn} + \sum_{n=1}^Q \eta_n \epsilon_{t-sn} + \epsilon_t$$

SARIMAX(p, d, q)(P, D, Q, s):

- Работает с нестационарными рядами
- Учитывает дополнительные факторы
- Моделирует сезонные паттерны

Как получить прогноз? ML / DL методы

Как получить прогноз? ML / DL методы

ML и DL методы можно более гибко адаптировать под задачу

Группа	Модель	Описание
ML методы	LightGBM (Merlion), CatBoost (ETNA , tsururu), py-boost (tsururu), LightAutoML	Feature eng. + strategies + GBM
DL методы	DLinear , RLinear , CycleNet	Линейные архитектуры
	NeuralProphet , NBEATS , DeepAR , LSTNet , TimesNet etc.	Другие архитектуры
	Informer , TFT , PatchTST , ITransformer , GPT2 , etc.	Трансформерные архитектуры

Как получить прогноз? Time Series → Tabular Data

Временной ряд можно представить в виде таблицы признаков и использовать ML и DL методы

«Длинная» таблица с
временным рядом

time	value	Additional features
0	4	...
1	4	...
2	5	...
3	6	...
4	3	...
5	2	...
6	8	...

$H = 2$
 $L = 3$
 $STEP = 1$

Составляем индексы



id	long ids features	long ids targets
0	[0, 1, 2]	[3, 4]
1	[1, 2, 3]	[4, 5]
2	[2, 3, 4]	[5, 6]

«Широкая» таблица со
сгенерированными признаками

Base ts	Current Value	Max Value	target1	target2
2	5	5	6	3
3	6	6	3	2
4	3	6	2	8

Какие признаки использовать?


- **Календарные признаки**
 - День недели, месяц, год (категориальные переменные)
 - Признаки на основе разложения Фурье
- **Лаговые признаки и признаки на основе разностей**
 - Значение вчера или год назад
 - Разница между текущим значением и значением вчера или год назад
- **Групповые статистики**
 - Средние, медианы, квантильные значения по группам (например, по дням недели)
 - Скользящие средние и стандартные отклонения (например, за 7 и 30 дней)
- **Признаки на основе статистических моделей**
 - ARIMA- или ETS-компоненты



Предобработка временных рядов (ч. 2)

Больше актуально для ML и DL:

- **StandardScaler / MinMaxScaler / RobustScaler** — контролируем диапазон значений.
- **WindowNormalizing** — боремся с артефактами на уровне окон.



Обучение Zero-shot models for time series

Группа	Модель	Описание
DL методы	LLMTime , Chronos , Moirai , Moment , TabPFN-TS	Фундаментальные модели



Как получить прогнозы?

Группы методов, которые используются на практике

Группа методов	Мало данных	Гибкость и адаптация	Многомерные ряды и внешние признаки
Naive methods	+	-	-
Statistical methods	+	+ -	+ -
ML methods	+ -	+ -	+
DL methods	-	+	+



Какую задачу решаем и как выстраиваем сравнение моделей?

Какие методы используем и как обрабатываем данные?


Что такое стратегии прогнозирования?

Какие выводы следует унести с собой и что еще посмотреть?

Как получить прогноз? Стратегии прогнозирования

Ряды на несколько точек вперед можно прогнозировать по-разному

Пусть длина всего ряда $N = 14$,
 история $L = 7$,
 горизонт прогнозирования $H = 3$.




Тогда по значениям в моменты времени от 0 до 10
хотим предсказать значения в моменты времени от 11 до 13.

MIMO (Multi-In-Multi-Out)

Одна модель для всех точек горизонта прогнозирования


Учим модель предсказывать сразу на H точек вперед.



Recursive / Rec-MIMO

Учим модель предсказывать на h точек вперед.

Итеративно строим прогнозы на основе уже полученных прогнозов.



MIMO (Multi-In-Multi-Out)

Плюсы: быстрое обучение и инференс, легко добавлять признаки.

Минусы: не подойдет для коротких рядов, длинный горизонт возможен только для длинных рядов.

Встречается: NLP (multitoken prediction).

Recursive / Rec-MIMO

Плюсы: быстрое обучение, хорошая метрика на короткие горизонты, требует малой длины ряда, можно получить прогноз на любой горизонт.


Минусы: медленный инференс на длинные горизонты, накопление ошибок, сложность использования экзогенных признаков.

Встречается: NLP (Causal LM), RecSys (next item prediction).

Direct / Direct-MIMO

Несколько индивидуальных моделей для каждой точки / отрезка горизонта прогнозирования

Учим i -ую модель предсказывать на h точек вперед через $(i - 1) \times h$ точек.



Одновременно строим прогнозы.



Плюсы: меньше накопление ошибки.

Минусы: нужно обучить и прогнать h моделей (но можно распараллелить), сложно использовать экзогенные признаки.

Как получить прогноз? Стратегии прогнозирования

Ряды на несколько точек вперед можно прогнозировать по-разному

Прогнозный горизонт модели

$$1 < h < H$$

Direct

Индивидуальная модель для каждой точки горизонта прогнозирования.

Recursive

Одна модель для всех точек горизонта прогнозирования. Предсказывает на одну точку вперед.

MIMO


Одна модель для всех точек горизонта прогнозирования. Предсказывает сразу все точки.

FlatWideMIMO

Развернутый по горизонтам предсказания MIMO.

Rectify

Сначала учим рекурсивную, а затем прямую на ошибках рекурсивной.




Соотношения между стратегиями предсказания

Зачем использовать разные стратегии?


std / strategy

0.1


Recursive






RecMIMO 10






MIMO



0.7



1




Local vs Global vs Multivariate modelling

Также можно выделить разные стратегии предсказания многомерного временного ряда

Local


Индивидуальная модель для каждого одномерного временного ряда.



Multivariate

Одна модель для всех одномерных временных рядов.

Признаки наблюдений, относящихся к одной временной точке, **объединяются**



Global

Одна модель для всех одномерных временных рядов.

Признаки отдельных наблюдений **не пересекаются** между рядами.




Что внутри библиотеки?

Различные компоненты пайплайна прогнозирования, которые полностью совместимы



На GitHub
репозиторий





Какую задачу решаем и как выстраиваем сравнение моделей?

Какие методы используем и как обрабатываем данные?

Что такое стратегии прогнозирования?

Какие выводы следует унести с собой и что еще посмотреть?

Какие выводы следует унести с собой?

1. Постепенно усложняем решение (Baseline -> Econometric -> ML -> DL).
2. Аккуратно подбираем метрики и протокол валидации особенности данных и постановки задачи.
3. Используем мощь стратегий и global / multivariate прогнозирования.

Ссылки

Репозитории:

- <https://nixtlaverse.nixtla.io/statsforecast/index.html> — StatsForecast (классические модели)
- <https://github.com/thuml/Time-Series-Library> — TSLib (DL модели)
- <https://huggingface.co/spaces/Salesforce/GIFT-Eval> — GIFT-Eval (бенчмарк)

Учебники и лекции:

- <https://otexts.com/fpp3/some-simple-statistics.html> — Forecasting: Principles and Practice (3rd ed) (Rob J Hyndman and George Athanasopoulos): несложный учебник, к которому можно обращаться как к входной точке, если возникла проблема
- [2.5-часовая лекция Christoph Bergmeir](#) про прогнозирование временных рядов
- <https://arxiv.org/abs/2203.10716> — Forecast Evaluation for Data Scientists: Common Pitfalls and Best Practices
- <https://github.com/elineii/HSE-Time-Series-2025/tree/main> — репозиторий с моими презентациями и ноутбуками с курса в магистратуре ИИ

Спасибо за внимание!

Костромина Алина

Центр Практического ИИ Сбера / Sber AI Lab, ML2.0

Май 2026



@ELINEII



@SB_AI_LAB